

TRƯỜNG ĐẠI HỌC THỦ DẦU MỘT
VIỆN ĐÀO TẠO CÔNG NGHỆ THÔNG TIN, CHUYỂN ĐỔI SỐ



BÁO CÁO MÔN HỌC
HỌC MÁY

TÊN ĐỀ TÀI

SVTH: Nguyễn Thị Ngọc Nhi 2224801030305

Lê Vũ Anh 2224801030388

Lê Đức Hải 2224801030325

GVHD: ThS. Hồ Ngọc Trung Kiên

TP.HCM, tháng 10/2025

TRƯỜNG ĐẠI HỌC THỦ DẦU MỘT
VIỆN ĐÀO TẠO CÔNG NGHỆ THÔNG TIN, CHUYÊN ĐỒI SỐ



BÁO CÁO MÔN HỌC
HỌC MÁY

TÊN ĐỀ TÀI

SVTH: Nguyễn Thị Ngọc Nhi 2224801030305

Lê Vũ Anh 2224801030388

Lê Đức Hải 2224801030325

GVHD: ThS. Hồ Ngọc Trung Kiên

TP.HCM, tháng 10/2025

NHẬN XÉT VÀ CHẤM ĐIỂM CỦA GIẢNG VIÊN

Họ và tên giảng viên: ThS. Hồ Ngọc Trung Kiên

Đề tài:

Nội dung nhận xét:

.....

.....

.....

.....

.....

.....

Điểm:

Bằng số:

Bằng chữ:

TP.HCM, ngày tháng 10 năm 2025

GIẢNG VIÊN

MỤC LỤC

DANH MỤC HÌNH	i
DANH MỤC BẢNG	ii
DANH MỤC VIẾT TẮT	iii
LỜI CẢM ƠN	iv
LỜI MỞ ĐẦU	v
CHƯƠNG 1. tổng quan về học máy.....	1
1.1. Giới thiệu chung.....	1
1.1.1. Lịch sử ra đời.....	1
1.1.2. Khái niệm.....	3
1.1.3. Phân loại học máy	5
1.1.4. Ứng dụng học máy	10
1.1.5. Quy trình (quá trình) học máy	14
1.1.6. Các vấn đề của học máy	17
1.2. Tập dữ liệu.....	19
1.2.1. Các kiểu dữ liệu.....	19
1.2.2. Các kiểu giá trị thuộc tính.....	19
1.2.3. Kiểu thuộc tính liên tục và rời rạc.....	20
1.2.4. Các đặc tính mô tả dữ liệu	21
1.2.5. Trực quan hóa dữ liệu	21
1.3. Tiền xử lý dữ liệu.....	22
1.3.1. Làm sạch dữ liệu	23
1.3.2. Tích hợp dữ liệu	24
1.3.3. Biến đổi dữ liệu.....	25
1.3.4. Giảm bớt dữ liệu	27
1.3.5. Các giải pháp của quá trình tiền xử lý dữ liệu	28
1.4. Đánh giá hiệu năng trong học máy.....	32
1.4.1. Các loại bài toán áp dụng.....	32

1.4.2. Các cách đánh giá hiệu năng và cách thực hiện chúng	36
TÀI LIỆU THAM KHẢO.....	40

DANH MỤC HÌNH

Hình 1.1 Lịch sử ra đời học máy	1
Hình 1.2 Sự khác biệt giữa lập trình truyền thống và học máy	3
Hình 1.3 Phân loại học máy.....	5
Hình 1.4 Học có giám sát	6
Hình 1.5 Học không giám sát	7
Hình 1.6 Học bán giám sát	7
Hình 1.7 Mô hình tương tác giữa tác nhân và môi trường trong học tăng cường.....	9
Hình 1.8 Mô tả các bước trong xử lý ảnh.....	11
Hình 1.9 Quy trình xây dựng mô hình Machine Learning	14
Hình 1.10 Biểu đồ dòng chảy hiển thị các loại dữ liệu	19
Hình 1.11 Quy trình tiền xử lý dữ liệu	22
Hình 1.12 Quy trình tích hợp dữ liệu	24
Hình 1.13 Biểu đồ Effort ước lượng.....	24
Hình 1.13 Quá trình chuẩn hóa dữ liệu	25
Hình 1.14 Quá trình giảm dữ liệu.....	27
Hình 1.15 Các giải pháp của quá trình tiền xử lý dữ liệu.....	28

DANH MỤC BẢNG

Bảng 1.1 Minh họa cách trình bày dữ liệu rời rạc khi so sánh 2 nhóm can thiệp	20
Bảng 1.2 Minh họa cách hiển thị dữ liệu liên tục so sánh 2 biện pháp can thiệp.....	21

DANH MỤC VIẾT TẮT

LỜI CẢM ƠN


LỜI MỞ ĐẦU

CHƯƠNG 1. TỔNG QUAN VỀ HỌC MÁY

1.1. Giới thiệu chung

1.1.1. Lịch sử ra đời

Thuật ngữ học máy (machine learning) đề cập đến việc phát hiện một cách tự động các mẫu có ý nghĩa trong dữ liệu. Trong vài thập kỷ qua, nó đã trở thành một công cụ phổ biến trong hầu hết mọi nhiệm vụ đòi hỏi information extraction từ các data set lớn. [2].



Hình 1.1 Lịch sử ra đời học máy

Giữa thế kỷ 20, Alan Turing, một trong những người tiên phong, đã đặt ra những câu hỏi cơ bản về tiềm năng của máy móc trong việc bắt chước các khía cạnh trí thông minh của con người trong bài báo quan trọng của ông "*Computing Machinery and Intelligence*". Trong công trình này, Turing đã nỗ lực trả lời câu hỏi "*máy móc có thể suy nghĩ không?*" và giới thiệu khái niệm hiện được gọi là Turing test. Phép thử này được thiết kế để đánh giá khả năng của máy móc trong việc thể hiện hành vi thông minh không thể phân biệt được với con người. Nó bao gồm một người *interrogator* tham gia vào một cuộc trò chuyện với cả con người và máy, trong khi cả hai đều ở ngoài tầm nhìn của người đó [1].

Năm 1943, Warren McCulloch và Walter Pitts đã công bố công trình đặt nền móng cho trí tuệ nhân tạo hiện đại. Họ giới thiệu mô hình toán học đầu tiên mô phỏng hoạt động của neuron nhân tạo. Mô hình này dựa trên logic và đại số Boolean để mô tả cách neuron xử lý thông tin. Đây được xem là bước khởi đầu quan trọng cho sự phát triển của mạng nơ-ron nhân tạo sau này [68].

Năm 1949, Donald Hebb xuất bản cuốn sách kinh điển "The Organization of Behavior". Trong đó, ông đề xuất quy tắc học nổi tiếng Hebbian Learning Rule. Nguyên lý này được tóm gọn bằng câu "neurons that fire together wire together". Đây là cơ sở quan trọng truyền cảm hứng cho nhiều cơ chế học trong mạng nơ-ron nhân tạo [69].

Năm 1951, Evelyn Fix và Joseph Hodges (Đại học California, Berkeley) đã trình bày báo cáo kỹ thuật mang tên "*Discriminatory Analysis. Nonparametric*

Discrimination: Consistency Properties” tại RAND Corporation. Đây được xem là công trình đầu tiên mô tả nguyên lý của phương pháp nearest neighbor cho bài toán phân loại – tức là dựa vào các điểm dữ liệu “láng giềng gần nhất” để suy luận nhãn của một điểm mới. Mặc dù thuật toán này chưa được biết đến rộng rãi tại thời điểm đó, nó đã đặt nền móng lý thuyết vững chắc cho các nghiên cứu sau này [5].

Năm 1952, Arthur Samuel, một nhà khoa học máy tính tại IBM, đã phát triển chương trình chơi cờ dam trên máy IBM 701. Điểm đặc biệt của chương trình này là khả năng tự cải thiện hiệu suất thông qua kinh nghiệm từ các ván đấu, thay vì chỉ dựa vào các quy tắc được lập trình sẵn. Công trình của Samuel đã mở ra một hướng nghiên cứu mới và được xem là một trong những ví dụ đầu tiên về *machine learning* trong lịch sử trí tuệ nhân tạo (Feigenbaum, 1990) [3].

Cuối thập niên 1950 Perceptron – mạng nơ-ron nhân tạo đầu tiên – được Frank Rosenblatt giới thiệu, đánh dấu một bước ngoặt quan trọng trong lịch sử phát triển của neural networks. Mô hình này được xây dựng như một phiên bản toán học đơn giản hóa của *biological neuron*, với mục tiêu thực hiện các nhiệm vụ classification. Điểm nổi bật của perceptron là khả năng tự động học các trọng số (weights) dựa trên sai số, đặt nền móng cho supervised learning [1].

Năm 1963, Marvin Minsky và Seymour Papert xuất bản cuốn sách “*Perceptrons*”. Trong đó, họ chỉ ra rằng perceptron đơn lớp không thể giải quyết được bài toán XOR, một ví dụ tiêu biểu cho dữ liệu không thể phân tách tuyến tính. Sự phê phán này khiến lĩnh vực nghiên cứu mạng nơ-ron rơi vào giai đoạn trầm lắng trong nhiều năm sau đó [1].

Năm 1967, Thomas Cover và Peter Hart công bố bài báo “*Nearest Neighbor Pattern Classification*” trên *IEEE Transactions on Information Theory*, chính thức phát triển và phân tích có hệ thống thuật toán k-Nearest Neighbors (k-NN). Hai tác giả chứng minh rằng tỷ lệ lỗi phân loại của k-NN không vượt quá hai lần tỷ lệ lỗi tối ưu theo lý thuyết Bayes – một phát hiện quan trọng củng cố tính hiệu quả của phương pháp này [4].

Năm 1986, J. R. Quinlan giới thiệu thuật toán ID3 (Iterative Dichotomiser 3) trong bài báo “*Induction of Decision Trees*”, sử dụng entropy và information gain để xây dựng cây quyết định tối ưu. Thuật toán này là tiền đề cho các cải tiến sau như C4.5 [6][7]. David Rumelhart, Geoffrey Hinton và Ronald Williams công bố thuật toán backpropagation, mở ra khả năng huấn luyện các mạng nơ-ron nhiều lớp (MLP) để học các đặc trưng phức tạp, từ đó ứng dụng mạnh mẽ trong nhận dạng hình ảnh, xử lý ngôn ngữ và nhiều lĩnh vực khác [9]. Cùng thời gian này, thuyết Connectionism phát triển mạnh. Nghiên cứu của David A. Medler đã cung cấp cái nhìn tổng quan về lịch sử, triết học, tâm lý học và nền tảng thần kinh của các mô hình mạng nơ-ron [8].

Năm 1995, Corinna Cortes và Vladimir Vapnik công bố bài báo “*Support-vector networks*”, giới thiệu Support Vector Machine (SVM) – một trong những mô hình học có giám sát quan trọng nhất, được ứng dụng rộng rãi trong phân loại và hồi quy [10].

Năm 2002, Nello Cristianini và Bernhard Schölkopf công bố bài báo “*Support Vector Machines and Kernel Methods: The New Generation of Learning Machines*”


trên *AI Magazine*. Công trình này hệ thống hóa và mở rộng kernel methods, giúp SVM và các thuật toán kernel trở thành thể hệ học máy mạnh mẽ, được ứng dụng trong phân loại văn bản, nhận dạng chữ viết tay và phân tích dữ liệu sinh học [11].

Năm 2012, Alex Krizhevsky, Ilya Sutskever và Geoffrey Hinton giới thiệu mô hình AlexNet, chiến thắng cuộc thi *ImageNet Large Scale Visual Recognition Challenge (ILSVRC 2012)*. Đây là cột mốc quan trọng, đánh dấu sự trỗi dậy của deep learning nhờ sự kết hợp giữa dữ liệu lớn và GPU [12].

Năm 2017, Ashish Vaswani và cộng sự tại Google Brain công bố bài báo “*Attention Is All You Need*”, giới thiệu kiến trúc Transformer, loại bỏ hoàn toàn hồi quy (RNN) và tích chập (CNN). Transformer nhanh chóng trở thành nền tảng cho các mô hình NLP hiện đại như BERT, GPT, GPT-3 và các mô hình AI tạo sinh sau này [13].

1.1.2. Khái niệm

Học máy (Machine Learning) là một lĩnh vực cốt lõi trong trí tuệ nhân tạo (Artificial Intelligence – AI) tập trung vào việc phát triển các thuật toán cho phép máy tính học từ dữ liệu và cải thiện hiệu suất theo thời gian mà không cần được lập trình cụ thể cho từng tác vụ. Hiểu đơn giản, thuật ngữ này nói tới việc con người dạy máy tính nâng cao khả năng thực hiện các tác vụ cụ thể. Trong học máy, hệ thống được huấn luyện để phát hiện ra các mẫu (patterns) trong dữ liệu, từ đó đưa ra các quyết định, phân loại hoặc dự đoán giá trị đầu ra cho dữ liệu mới.



Hình 1.2 Sự khác biệt giữa lập trình truyền thống và học máy

Theo góc nhìn một số nhà nghiên cứu, machine learning (học máy) được hiểu như sau:

Với Tom Mitchell, ông đã đề xuất một định nghĩa của học máy như sau: “Một chương trình máy tính được cho là học hỏi từ kinh nghiệm E liên quan đến một số loại nhiệm vụ T và thước đo hiệu suất P nếu hiệu suất của nó tại các nhiệm vụ trong T, được đo bằng P, được cải thiện theo kinh nghiệm E” [14].

Hay là trước đó đã có một phát biểu được cho là của Arthur Samuel vào năm

1959 được xem là định nghĩa sớm nhất của học máy như sau: ” Học máy là lĩnh vực nghiên cứu cho phép máy tính có khả năng học mà không cần được lập trình một cách tường minh” [15].

Ở một nghiên cứu khác, Issam El Naqa và cộng sự của ông đã nêu trong Machine Learning in Radiation Oncology, học máy là một nhánh đang phát triển của các thuật toán tính toán, được thiết kế để mô phỏng trí thông minh của con người bằng cách học hỏi từ môi trường xung quanh. Chúng được coi là lực lượng nòng cốt trong kỷ nguyên mới của cái gọi là dữ liệu lớn. Các kỹ thuật dựa trên học máy đã được ứng dụng thành công trong nhiều lĩnh vực, từ nhận dạng mẫu, thị giác máy tính, kỹ thuật tàu vũ trụ, tài chính, giải trí và sinh học tính toán đến các ứng dụng y sinh và y tế [16].

Hoặc theo một vài nghiên cứu về học máy hiện đại đã định nghĩa “Học máy là một nhánh của khoa học máy tính có tiềm năng chuyển đổi ngành khoa học dịch tễ học. Trong bối cảnh "Dữ liệu lớn" ngày càng được chú trọng, nó cung cấp cho các nhà dịch tễ học những công cụ mới để giải quyết các vấn đề mà các phương pháp cổ điển không phù hợp” [17].

Theo Nilson, N. J vào năm 1996 trong cuốn “Introduction to machine learning”: “Một định nghĩa khá “mềm” của học máy là việc sử dụng máy tính để thực hiện các tác vụ mà chúng có thể tự học và ngày càng làm tốt hơn mà không cần phải được lập trình cụ thể từng bước” [18].

Theo Y. Lecun và các cộng sự đã nêu trong Gradient-based learning applied to document recognition (1998) rằng: “Các mạng nơ-ron sâu có khả năng tự động học các đặc trưng từ dữ liệu thông qua nhiều lớp biểu diễn trừu tượng, thay vì cần lập trình thủ công các đặc trưng” [19].

Trong nghiên cứu vào năm 2010 của James L. Crowley and Nachwa Aboubakr: “Học máy nghiên cứu và xây dựng các thuật toán có khả năng học các hàm số từ dữ liệu. Học máy cho nhận dạng mẫu (Pattern Recognition) là hình thức phổ biến nhất của học máy, nhưng đó chỉ là một trong nhiều hình thức khác nhau” [23].

Năm 2016, một cuốn sách mang tên Deep Learning (học sâu) do Ian Goodfellow và các cộng sự đã chỉ ra: “Học sâu là một nhánh của học máy cho phép máy tính học từ kinh nghiệm và hiểu thế giới thông qua các cấp bậc khái niệm được tổ chức theo dạng phân cấp. Nhờ khả năng tự học thông qua dữ liệu đầu vào, hệ thống không cần con người chỉ rõ từng đặc trưng cụ thể trong quá trình xử lý” [20].


Học sâu hoạt động bằng cách xây dựng những khái niệm phức tạp dựa trên những khái niệm đơn giản hơn, được tổ chức thành nhiều lớp trừu tượng (layers) – do đó mô hình có thể đại diện và mô phỏng những mối quan hệ phức tạp trong dữ liệu [20].

Cuốn sách “Python Machine Learning” năm 2017 của Sebastian Raschka có đề cập đến: “Học máy là một ngành con của khoa học máy tính, tập trung xây dựng các thuật toán, mà để hữu ích thì cần dựa vào một tập ví dụ về hiện tượng nào đó” [22].

Trong lĩnh vực phân tích dữ liệu, học máy được xem như một phương pháp mạnh mẽ nhằm xây dựng và triển khai các mô hình phức tạp cùng thuật toán dự đoán. Trong bối cảnh ứng dụng thực tiễn và lĩnh vực kinh doanh, phương pháp này thường được gọi là phân tích dự báo (predictive analytics). Các mô hình phân tích dựa trên học máy giúp các nhà khoa học, những kỹ sư và nhiều tổ chức phân tích và ra quyết định một cách chính xác, đáng tin cậy và có thể lặp lại, đồng thời hỗ trợ khai phá những tri thức tiềm ẩn thông qua việc học từ các mối quan hệ, xu hướng trong dữ liệu [21].


1.1.3. Phân loại học máy

Để phân tích dữ liệu một cách thông minh và phát triển các ứng dụng tự động hóa tương ứng, kiến thức về trí tuệ nhân tạo (AI), đặc biệt là học máy (ML), giữ vai trò then chốt. Trong lĩnh vực này tồn tại nhiều loại thuật toán học máy khác nhau như học có giám sát (supervised (inductive) learning), học không giám sát (unsupervised learning), học bán giám sát (semi-supervised learning) và học tăng cường (reinforcement learning). Bên cạnh đó, học sâu (deep learning) – một nhánh quan trọng của học máy – cho phép phân tích dữ liệu ở quy mô lớn một cách hiệu quả và thông minh [25].



Hình 1.3 Phân loại học máy

Học có giám sát (supervised learning), thường là nhiệm vụ của học máy nhằm học một hàm ánh xạ từ đầu vào sang đầu ra dựa trên các cặp dữ liệu mẫu đầu vào – đầu ra. Phương pháp này sử dụng dữ liệu huấn luyện đã được gán nhãn cùng với tập hợp các ví dụ huấn luyện để suy ra hàm ánh xạ. Học có giám sát được áp dụng khi có những mục tiêu cụ thể cần đạt được từ một tập hợp đầu vào xác định, tức là một cách tiếp cận định hướng theo nhiệm vụ. Hai dạng bài toán phổ biến nhất trong học có giám sát là **phân loại (classification)** – nhằm phân tách dữ liệu, và **hồi quy (regression)** – nhằm ước lượng, khớp dữ liệu. Ví dụ, việc dự đoán nhãn lớp hoặc cảm xúc của một đoạn văn bản, như một dòng tweet hay một đánh giá sản phẩm (bài toán phân loại văn bản), là một minh chứng điển hình cho học có giám sát [26].




Hình 1.4 Học có giám sát

Một số thuật toán phân loại nổi tiếng bao gồm ZeroR , OneR , Naive Bayes, Decision Tree, K-nearest neighbors (KNN), Support Vector Machines (SVM), Adaptive Boosting (AdaBoost), và Logistic Regression. Trong khi đó, các kỹ thuật hồi quy được sử dụng để dự đoán giá trị liên tục hoặc số liệu, chẳng hạn như dự đoán tổng số vụ tấn công lừa đảo (phishing) trong một khoảng thời gian hoặc dự đoán các tham số gói tin mạng. Phân tích hồi quy cũng có thể được áp dụng để phát hiện nguyên nhân gốc rễ của tội phạm mạng và các dạng gian lận khác. Một số thuật toán hồi quy phổ biến gồm Linear Regression và Support Vector Regression (SVR) [27].

Học không giám sát (Unsupervised learning) là một phương pháp học máy trong đó thuật toán chỉ được cung cấp dữ liệu đầu vào mà không có nhãn đầu ra, tức là một quá trình dựa trên dữ liệu (data-driven). Phương pháp này thường được sử dụng để trích xuất đặc trưng sinh (generative features), nhận diện các xu hướng và cấu trúc có ý nghĩa, nhóm dữ liệu (groupings) cũng như phục vụ mục đích khám phá [26].

Như Russell (2003) đã chỉ ra: “Học không giám sát là một phương pháp học máy, trong đó mô hình được xây dựng từ các quan sát. Nó khác với học có giám sát ở chỗ không tồn tại đầu ra được xác định trước (a priori output). Trong học không giám sát, một tập dữ liệu đầu vào được thu thập và thường được xem như một tập biến ngẫu nhiên. Sau đó, một mô hình mật độ kết hợp được xây dựng cho tập dữ liệu.




Hình 1.5 Học không giám sát

Vấn đề của học không giám sát liên quan đến việc tìm ra các mẫu trong dữ liệu đầu vào khi không có các giá trị đầu ra cụ thể được cung cấp”. Các nhiệm vụ phổ biến nhất của học không giám sát bao gồm: phân cụm (clustering), ước lượng mật độ (density estimation), học đặc trưng (feature learning), giảm chiều dữ liệu (dimensionality reduction), tìm luật kết hợp (association rules), phát hiện bất thường (anomaly detection)... [25].

Ví dụ điển hình của học không giám sát là phân cụm (clustering), nơi các đối tượng dữ liệu được nhóm lại dựa trên sự tương đồng. Điểm khác biệt so với học có giám sát là ở chỗ không tồn tại giá trị đầu ra chuẩn (a priori output) để so sánh.

Như tên gọi, **học bán giám sát (semi-supervised learning)** nằm ở giữa học không giám sát và học có giám sát, vì nó hoạt động trên cả dữ liệu có nhãn và dữ liệu không nhãn. Do đó, nó nằm giữa học “không có giám sát” và học “có giám sát”. Trong thế giới thực, dữ liệu có nhãn có thể hiếm trong nhiều ngữ cảnh, trong khi dữ liệu không nhãn lại rất phong phú, và khi đó học bán giám sát tỏ ra hữu ích. Mục tiêu cuối cùng của mô hình học bán giám sát là mang lại kết quả dự đoán tốt hơn so với chỉ sử dụng dữ liệu có nhãn đơn thuần. Một số lĩnh vực ứng dụng của học bán giám sát bao gồm dịch máy, phát hiện gian lận, gán nhãn dữ liệu, và phân loại văn bản [26].

Học bán giám sát (Semi-supervised learning) đã phát triển thành một lĩnh vực nghiên cứu rộng lớn trong học máy. Ví dụ, một tìm kiếm với cụm từ “semi-supervised” vào tháng 5 năm 2009 đã cho ra hơn 8000 bài báo trên Google Scholar [28].



Hình 1.6 Học bán giám sát

Cụ thể, học bán giám sát bao gồm nhiều thiết lập khác nhau, trong đó phổ biến nhất là: phân loại bán giám sát (Semi-supervised classification) và phân cụm có ràng buộc (Constrained clustering) [28].

Phân loại bán giám sát (Semi-supervised classification): còn được gọi là phân loại với dữ liệu vừa có nhãn vừa không nhãn (hoặc dữ liệu gán nhãn một phần). Đây là sự mở rộng của bài toán phân loại có giám sát. Mục tiêu của phân loại bán giám sát là huấn luyện một bộ phân loại sử dụng đồng thời cả dữ liệu có nhãn và không nhãn, sao cho đạt hiệu quả tốt hơn so với mô hình chỉ học từ dữ liệu có nhãn.

Phân cụm có ràng buộc (Constrained clustering): là sự mở rộng của phương pháp phân cụm không giám sát. Tập dữ liệu bao gồm các mẫu không nhãn cùng với một số thông tin giám sát bổ sung về các cụm. Mục tiêu của phân cụm có ràng buộc là đạt được kết quả phân cụm tốt hơn so với việc chỉ sử dụng dữ liệu không nhãn.

Nghiên cứu về học bán giám sát được thúc đẩy bởi hai yếu tố chính: giá trị thực tiễn trong việc xây dựng các thuật toán máy tính hiệu quả hơn, và giá trị lý thuyết trong việc hiểu rõ hơn cơ chế học của máy và con người [28] .


Reinforcement learning (học tăng cường) là một dạng thuật toán học máy cho phép tác nhân phần mềm hoặc máy móc tự động đánh giá hành vi tối ưu trong một ngữ cảnh hoặc môi trường cụ thể nhằm cải thiện hiệu suất. Đây là một phương pháp học dựa trên thưởng và phạt, với mục tiêu cuối cùng là tận dụng thông tin từ môi trường để đưa ra hành động giúp tối đa hóa phần thưởng hoặc giảm thiểu rủi ro. Học tăng cường được xem là công cụ mạnh mẽ trong việc huấn luyện các mô hình AI, đặc biệt hữu ích để tăng cường khả năng tự động hóa và tối ưu hóa hiệu quả vận hành của các hệ thống phức tạp như robotics, xe tự hành, sản xuất và logistics chuỗi cung ứng. Tuy nhiên, nó không phải là lựa chọn phù hợp cho các vấn đề cơ bản hoặc đơn giản [26].

Học tăng cường là một lĩnh vực kết hợp giữa khoa học máy tính và tâm lý học hành vi, mang tính khái quát hóa cao, không giới hạn trong một kỹ thuật duy nhất mà là một khung lý thuyết để giải quyết nhiều dạng bài toán học hành vi [29].

So với học có giám sát học tăng cường không có sự trình bày các cặp đầu vào/đầu ra. Thay vào đó, sau khi chọn một hành động, tác nhân chỉ nhận được phần thưởng tức thời và trạng thái tiếp theo, nhưng không được cho biết hành động nào sẽ mang lại lợi ích tốt nhất trong dài hạn. Do đó, tác nhân cần chủ động thu thập những kinh nghiệm hữu ích về các trạng thái hệ thống có thể xảy ra, các hành động, sự chuyển đổi và phần thưởng để có thể hành động một cách tối ưu. Một điểm khác biệt nữa so với học có giám sát là hiệu suất trực tuyến có ý nghĩa quan trọng: việc đánh giá hệ thống thường diễn ra đồng thời với quá trình học [29].

Một số khía cạnh của học tăng cường (reinforcement learning) có mối liên hệ chặt chẽ với các vấn đề về tìm kiếm (search) và lập kế hoạch (planning) trong trí tuệ nhân tạo. Các thuật toán tìm kiếm trong AI thường tạo ra một quỹ đạo (trajectory) thỏa mãn khi di chuyển qua đồ thị các trạng thái. Lập kế hoạch cũng vận hành theo cách tương tự, nhưng thường trong một cấu trúc phức tạp hơn đồ thị, nơi mà các trạng thái được biểu diễn bằng sự kết hợp của các biểu thức logic thay vì các ký hiệu nguyên tử đơn lẻ.

Tuy nhiên, các thuật toán AI này có phạm vi khái quát hẹp hơn so với các phương pháp học tăng cường, bởi vì chúng đòi hỏi một mô hình xác định trước về sự chuyển đổi trạng thái, và trong phần lớn trường hợp giả định tính tất định. Ngược lại, học tăng cường, ít nhất trong các trường hợp rời rạc mà lý thuyết đã được phát triển, giả định rằng toàn bộ không gian trạng thái có thể được liệt kê và lưu trữ trong bộ nhớ — một giả định mà các thuật toán tìm kiếm truyền thống không nhất thiết phải phụ thuộc vào [29].



Hình 1.7 Mô hình tương tác giữa tác nhân và môi trường trong học tăng cường

Trong mô hình Agent–Environment Interface của học tăng cường, một tác nhân (agent) tương tác liên tục với môi trường (environment) thông qua một vòng lặp thử – sai. Tại mỗi bước thời gian t , tác nhân quan sát trạng thái hiện tại s_t và lựa chọn một hành động a_t . Sau khi hành động được thực hiện, môi trường phản hồi bằng cách cung cấp phần thưởng r_{t+1} và cập nhật sang trạng thái mới s_{t+1} . Thông tin này quay trở lại tác nhân, giúp nó điều chỉnh chiến lược hành động để tối đa hóa tổng phần thưởng tích lũy dài hạn. Quá trình này được lặp lại theo các bước thời gian rời rạc $t=0,1,2,\dots$ và chính là cơ chế cốt lõi giúp tác nhân học hỏi và cải thiện hiệu suất trong Reinforcement Learning [30].

RL đã được sử dụng trong nhiều ứng dụng trong những năm gần đây một số lĩnh vực và ứng dụng của RL khá phổ biến bao gồm: natural Language Processing (Xử lý ngôn ngữ tự nhiên), Finance (Tài chính), Robotics (Ngành robot), Security (An ninh mạng), Gaming (Trò chơi / Trí tuệ nhân tạo trong game) – một số game kinh điển như AlphaGo, Atari,... Marketing (Tiếp thị), Automated vehicle (Phương tiện tự động), Energy Management (Quản lý năng lượng) [31].

Học sâu, vốn gắn liền với mạng nơ-ron nhân tạo (ANN), về bản chất là quá trình học các khái niệm theo tầng bậc. Trong các mô hình này, những khái niệm ở mức thấp và mức cao sẽ được biểu diễn tại các lớp khác nhau trong cấu trúc mạng. Chẳng hạn, một số nhà khoa học đã sử dụng một mạng nơ-ron nhiều lớp — mà họ gọi là phương pháp học sâu — để chuyển đổi các đồ thị phân tử thành một tập hợp các đặc trưng, rồi thông qua một hàm đầu ra thích hợp để dự đoán độ tan trong nước.

Kết quả cho thấy mô hình này đạt được khả năng dự đoán tốt, có tính cạnh tranh với nhiều phương pháp học máy tiên tiến khác. Đáng chú ý, mô hình thực tế là một tập hợp (ensemble) gồm 20 mạng nơ-ron khác nhau, mỗi mạng có kiến trúc hơi khác biệt [14].

1.1.4. Ứng dụng học máy

Trong thời đại **Cách mạng Công nghiệp 4.0**, lĩnh vực học máy (ML) là một trong những lĩnh vực năng động và hấp dẫn nhất. Trong vài thập kỷ qua, ML đã len lỏi vào cuộc sống hàng ngày của chúng ta, mang đến những giải pháp hiệu quả cho các thách thức thực tế. Phạm vi ứng dụng của ML trải rộng trên nhiều lĩnh vực, bao gồm kỹ thuật, công nghiệp, kinh doanh, tài chính, y học, v.v.

1.1.4.1. Phân tích dự đoán và ra quyết định thông minh

Bằng cách khai thác mối quan hệ giữa các biến giải thích và biến cần dự đoán, học máy có thể: nhận diện tội phạm, phát hiện gian lận thẻ tín dụng theo thời gian thực; hỗ trợ thương mại điện tử: hiểu rõ hành vi khách hàng, quản lý tồn kho, tránh thiếu hàng, tối ưu logistics [26].

Các thuật toán học máy khác nhau như cây quyết định, máy vector hỗ trợ, mạng nơ-ron nhân tạo,... thường được sử dụng trong lĩnh vực này. Vào tháng 12 năm 2021, Bryan Kelly, người đứng đầu bộ phận học máy tại công ty định lượng AQR Capital Management, đã đưa tên mình vào một bài báo học thuật gây xôn xao dư luận. Nghiên cứu "The Virtue of Complexity in Return Prediction" — đồng tác giả bởi Kelly, Semyon Malamud và Kangying Zhou — đã phát hiện ra rằng các mô hình học máy phức tạp tốt hơn các mô hình đơn giản trong việc dự đoán giá cổ phiếu và xây dựng danh mục đầu tư [33].

1.1.4.2. Thương mại điện tử & gợi ý sản phẩm (E-Commerce & Recommendations)

Gợi ý sản phẩm là một trong những ứng dụng nổi tiếng và được sử dụng rộng rãi nhất của học máy, và nó cũng là một trong những tính năng nổi bật nhất của hầu hết các trang web thương mại điện tử ngày nay. Công nghệ học máy có thể hỗ trợ doanh nghiệp phân tích lịch sử mua sắm của người tiêu dùng và đưa ra các gợi ý sản phẩm tùy chỉnh cho lần mua tiếp theo dựa trên hành vi và sở thích của họ. [26] Recommendations trong các lĩnh vực và bối cảnh cụ thể có thể được xem là thông tin phụ quan trọng ảnh hưởng đến mục tiêu khuyến nghị. Các loại bối cảnh khác nhau như dữ liệu thời gian, dữ liệu không gian, dữ liệu xã hội, dữ liệu gắn thẻ và độ tin cậy sẽ được khám phá [35].

Ở Amazon.com họ đã áp dụng các thuật toán gợi ý để cá nhân hóa trải nghiệm mua sắm trực tuyến cho từng khách hàng. Giao diện cửa hàng trực tuyến sẽ thay đổi đáng kể dựa trên sở thích và hành vi, chẳng hạn một kỹ sư phần mềm sẽ thấy nhiều tựa sách lập trình, trong khi một bà mẹ mới sinh có thể thấy gợi ý đồ chơi trẻ em. Vấn đề gợi ý thường được giải quyết bằng ba hướng tiếp cận chính: **lọc cộng tác truyền thống (traditional collaborative filtering)**, **mô hình phân cụm (cluster models)** và **phương pháp dựa trên tìm kiếm (search-based methods)**. Tuy nhiên, Amazon đã phát triển một thuật toán riêng gọi là **item-to-item collaborative**

filtering, cho phép tính toán trực tuyến có khả năng mở rộng độc lập với số lượng khách hàng và số lượng sản phẩm trong kho dữ liệu [34].

Ngoài ra, việc áp dụng học máy (machine learning) cũng rất phổ biến trong các sàn thương mại nổi tiếng hiện nay như: Shoppe, Tiki, Lazada,...

1.1.4.3. Về Y tế

Học máy có thể giúp giải quyết các vấn đề chẩn đoán và dự đoán trong nhiều lĩnh vực y tế, chẳng hạn như dự đoán bệnh, trích xuất kiến thức y học, phát hiện quy luật trong dữ liệu, quản lý bệnh nhân, [26] Công nghệ AI và ML được sử dụng để cải thiện độ chính xác của dự đoán sàng lọc cả bệnh truyền nhiễm và không truyền nhiễm [36].

Lịch sử thế giới đã chứng kiến một số đợt bùng phát dịch bệnh xâm chiếm nhân loại. Tổ chức Y tế Thế giới (WHO), các bác sĩ lâm sàng hợp tác và nhiều cơ quan quốc gia trên toàn cầu đang nỗ lực chống lại những đại dịch này cho đến nay [36]. Theo Tổ chức Y tế Thế giới (WHO), bệnh coronavirus (COVID-19) là một bệnh truyền nhiễm do một loại coronavirus mới gây ra. Gần đây, các kỹ thuật học máy đã trở nên phổ biến trong cuộc chiến chống lại COVID-19 [26]. Với sự trợ giúp của học máy, các nhà nghiên cứu có thể dự báo nơi và thời điểm COVID-19 có khả năng lây lan và cảnh báo cho các khu vực đó để chuẩn bị kịp thời.

Nhìn chung, các kỹ thuật học máy và học sâu có thể giúp chống lại virus COVID-19 và đại dịch cũng như hỗ trợ ra quyết định lâm sàng thông minh trong lĩnh vực y tế.

1.1.4.4. Nhận dạng hình ảnh giọng nói và mẫu

Học máy và thị giác máy tính hy vọng sẽ mang đến cho máy tính khả năng của con người trong việc cảm nhận dữ liệu, hiểu dữ liệu và thực hiện hành động dựa trên kết quả trong quá khứ và hiện tại. Đây là một lĩnh vực nghiên cứu đang phát triển mạnh mẽ. Thị giác máy tính đóng vai trò quan trọng trong IoT, IIoT và giao diện não – máy (brain-computer interfaces). Các hoạt động phức tạp của con người có thể được nhận diện và giám sát trong các luồng dữ liệu đa phương tiện nhờ sự kết hợp giữa học máy và thị giác máy tính. Hiện nay có nhiều phương pháp phân tích và dự đoán được sử dụng rộng rãi như học có giám sát (supervised learning), học không giám sát (unsupervised learning), ...[37].

Thị giác máy tính sử dụng hình ảnh và ảnh xạ mẫu để tìm ra giải pháp. Nó coi hình ảnh như một mảng các điểm ảnh. Thị giác máy tính tự động hóa các tác vụ giám sát, kiểm tra và theo dõi. Học máy là một tập hợp con của trí tuệ nhân tạo. Việc phân tích/chú thích tự động các video là kết quả của thị giác máy tính và học máy [37].



Hình 1.8 Mô tả các bước trong xử lý ảnh

Trong nghiên cứu “*Traffic Pattern Classification in Smart Cities Using Deep Recurrent Neural Network*”, các tác giả **Ayad Ghany Ismaeel cùng cộng sự** đã đề xuất một phương pháp mới để phân loại mẫu lưu lượng giao thông trong các thành phố thông minh, sử dụng mạng nơ-ron hồi tiếp sâu (Deep Recurrent Neural Network). Mô hình này kết hợp các tầng **convolutional (CNN)** và **recurrent (RNN)** để trích xuất đặc trưng từ dữ liệu giao thông theo chuỗi thời gian, sau đó sử dụng lớp **Softmax** để phân loại các mẫu lưu lượng. Kết quả thực nghiệm trên bộ dữ liệu thực tế cho thấy mô hình đạt độ chính xác vượt trội, với **precision lên đến 95%**, đồng thời vượt trội hơn các phương pháp hiện có về các chỉ số như accuracy, recall và F1-score [38].

1.1.4.5. Kinh tế, tài chính

Một số bài báo tổng quan cho thấy tiềm năng của ML trong tài chính. Varian (2014) mô tả ML là một công cụ phù hợp trong phân tích kinh tế dữ liệu lớn và trình bày một số phương pháp ML kèm theo ví dụ trong kinh tế học. Ông cũng gợi ý thêm về các ứng dụng ML tiềm năng trong kinh tế lượng. Mullainathan và Spiess (2017) xác định các vấn đề dự đoán là trường hợp sử dụng chính của ML trong kinh tế học và trình bày các danh mục ứng dụng hiện có và tiềm năng trong tương lai khác nhau. Athey và Imbens (2019) minh họa các phương pháp ML phù hợp nhất từ góc độ kinh tế lượng. Họ cũng cung cấp cái nhìn tổng quan về tiềm năng của ML vượt ra ngoài phạm vi dự đoán thuần túy, đặc biệt là về tính nhân quả trong các vấn đề kinh tế [39].

Trong những năm gần đây, mặc dù học máy (Machine Learning – ML) vẫn còn tương đối mới mẻ trong lĩnh vực nghiên cứu tài chính, nhưng phương pháp này đã nhanh chóng được chấp nhận rộng rãi trong cộng đồng khoa học. Tỷ lệ các bài báo sử dụng ML đã tăng trưởng đáng kể và chiếm khoảng 3–4% tổng số ấn phẩm trên ba tạp chí tài chính hàng đầu (*The Journal of Finance*, *Journal of Financial Economics*, *The Review of Financial Studies*) vào năm 2021.[39] Đặc biệt, phân tích cho thấy hai mảng chính của tài chính là thị trường tài chính/định giá tài sản và ngân hàng/tài chính doanh nghiệp đang khai thác tiềm năng của ML theo những cách tiếp cận khác nhau về bản chất.

Bài nghiên cứu *Machine Learning for Financial Statement Analysis* đã áp dụng các phương pháp học máy để dự đoán lợi nhuận bất thường của cổ phiếu xung quanh các thông báo thu nhập, chỉ dựa trên dữ liệu báo cáo tài chính quá khứ. Các tác giả đã so sánh nhiều mô hình trong kho công cụ học máy và phát hiện rằng Random Forests tạo ra dự báo chính xác nhất và mang lại lợi nhuận bất thường cao nhất [40].

1.1.4.6. Giáo dục

Ngày nay, Học máy (ML) là một trong những lĩnh vực ứng dụng đầy hứa hẹn nhất trong lĩnh vực Công nghệ Thông tin, nơi phạm vi ứng dụng của nó gần như không giới hạn. Ứng dụng của học máy trong lĩnh vực giáo dục hiện đang rất được các nhà nghiên cứu và nhà khoa học quan tâm. Các lớp học ngày nay sử dụng các nguồn lực kỹ thuật số và đang đầu tư vào học máy. Ví dụ, trong giáo dục, học máy có thể được ứng dụng để hỗ trợ giáo viên, dự đoán kết quả học tập của học sinh, kiểm tra học sinh,...[41]

Trong một nghiên cứu gần đây (*Using Machine Learning to Identify the Most At-Risk Students in Physics Classes*), các thuật toán học máy đã được sử dụng để dự đoán kết quả học tập của sinh viên trong lớp Vật lý nhập môn, Jie Yang và cộng sự đã phát triển mô hình học máy nhằm phân loại sinh viên có khả năng đạt điểm cao (A/B) hoặc có nguy cơ đạt điểm thấp, bỏ học (DFW). Mặc dù dữ liệu đầu vào bị mất cân bằng (với tỷ lệ DFW chỉ chiếm 10–20%), nhóm nghiên cứu đã tối ưu mô hình để cải thiện độ chính xác trong việc dự đoán DFW từ 16% lên đến 43%, và cuối cùng đạt đến 53% vào tuần đầu tiên của khóa học, khi kết hợp dữ liệu trong lớp và từ tổ chức. Kết quả này cho thấy khả năng mạnh mẽ của học máy trong phát hiện sớm những sinh viên cần hỗ trợ, từ đó tăng hiệu quả giảng dạy và hỗ trợ học tập cá nhân hóa [42].

1.1.4.7. Xử lý ngôn ngữ tự nhiên (NLP) và phân tích cảm xúc

Trợ lý ảo, chatbot, nhận dạng giọng nói, mô tả tài liệu, dịch ngôn ngữ hoặc dịch máy, v.v. là một số ví dụ về các tác vụ liên quan đến NLP. Phân tích cảm xúc (còn gọi là khai thác ý kiến hoặc AI cảm xúc) là một lĩnh vực con của NLP nhằm xác định và trích xuất tâm trạng và quan điểm công chúng trong một văn bản nhất định thông qua blog, đánh giá, mạng xã hội, diễn đàn, tin tức, v.v. [26]

Ví dụ: doanh nghiệp và thương hiệu sử dụng phân tích cảm xúc để hiểu rõ tình cảm xã hội đối với thương hiệu, sản phẩm hoặc dịch vụ của họ thông qua các nền tảng mạng xã hội hoặc toàn bộ Internet.

Ngành NLP (National Language Processing - Xử lý ngôn ngữ tự nhiên) đang phát triển mạnh mẽ, và một đánh giá tranh luận gần đây của các chuyên gia ước tính rằng chỉ đến năm 2050, tất cả máy tính thông minh sẽ có khả năng thực hiện bất kỳ công việc trí tuệ nào mà một cá nhân có thể thực hiện [43].

Ngày nay, với sự trợ giúp của Google và các dịch vụ tương tự, hàng triệu trang web có thể được đánh giá trong vòng chưa đầy một giây. NLP cung cấp cho máy tính khả năng thực hiện nhiều hoạt động liên quan đến ngôn ngữ tự nhiên ở nhiều cấp độ khác nhau, từ xử lý và gắn nhãn từ loại (POS) đến diễn giải máy và nền tảng hội thoại [43].

1.1.4.8. An ninh mạng


An ninh mạng là một trong những lĩnh vực thiết yếu của Công nghiệp 4.0, thường được hiểu là việc bảo vệ mạng, hệ thống, phần cứng và dữ liệu khỏi các cuộc tấn công kỹ thuật số. Học máy đã trở thành một công nghệ an ninh mạng then chốt, liên tục học hỏi bằng cách phân tích dữ liệu để xác định các mẫu, phát hiện phần mềm độc hại trong lưu lượng được mã hóa, tìm ra các mối đe dọa nội bộ, dự đoán các “khu vực nguy hiểm” trực tuyến, giữ an toàn cho người dùng khi duyệt web hoặc bảo mật dữ liệu trên đám mây bằng cách phát hiện hoạt động đáng ngờ [26].

Các mô hình bảo mật dựa trên học sâu có khả năng xử lý và phân tích hiệu quả các tập dữ liệu bảo mật quy mô lớn. Bên cạnh đó, các quy tắc chính sách được tạo ra nhờ kỹ thuật học luật kết hợp có thể trở thành nền tảng quan trọng cho việc xây dựng hệ thống bảo mật định hướng theo luật. Như vậy, có thể khẳng định rằng nhiều kỹ thuật học máy được đề cập trong phần Machine Learning Tasks and Algorithms

sẽ hỗ trợ các chuyên gia an ninh mạng chủ động hơn trong việc phòng ngừa và ứng phó hiệu quả với các mối đe dọa cũng như các cuộc tấn công mạng [26].

1.1.5. Quy trình (quá trình) học máy

Học máy là một nhánh của trí tuệ nhân tạo, tập trung vào việc xây dựng các thuật toán và mô hình giúp máy tính có khả năng tự học và đưa ra dự đoán hoặc quyết định mà không cần được lập trình chi tiết trước. Quá trình này thường khá phức tạp, bao gồm nhiều giai đoạn như: xác định vấn đề, thu thập và tiền xử lý dữ liệu, lựa chọn thuật toán phù hợp, huấn luyện mô hình, đánh giá hiệu quả hoạt động và tiếp tục cải thiện thông qua việc lặp lại khi cần thiết.



Hình 1.9 Quy trình xây dựng mô hình Machine Learning

Giai đoạn đầu liên quan đến các nhiệm vụ xác định mục tiêu kinh doanh và chuyển đổi thành các mục tiêu Học máy (ML), thu thập và xác minh chất lượng dữ liệu và cuối cùng là đánh giá tính khả thi của dự án. Điều này liên quan đến việc hiểu rõ ràng nhiệm vụ trước mắt và xác định những gì bạn muốn mô hình học. Một dự án ML có thể bị trì hoãn cho đến khi dữ liệu được thu thập hoặc thậm chí có thể bị dừng lại nếu việc thu thập dữ liệu có chất lượng không khả thi [45].

Trong bối cảnh dữ liệu lớn, việc thu thập dữ liệu chính xác và có khả năng mở rộng trở thành một yêu cầu cấp thiết, do đó nhiều nghiên cứu đã tập trung khảo sát các phương pháp thu thập dữ liệu từ góc độ quản lý dữ liệu. Nhìn chung, có ba hướng tiếp cận chính. Thứ nhất, sử dụng các kỹ thuật thu nhận dữ liệu (data acquisition) để tìm kiếm, bổ sung hoặc sinh ra các tập dữ liệu mới, phục vụ mục tiêu mở rộng kho dữ liệu. Thứ hai, khi dữ liệu đã có sẵn, có thể áp dụng các phương pháp gán nhãn dữ liệu (data labeling) nhằm phân loại và định nghĩa rõ các mẫu dữ liệu, hỗ trợ cho việc huấn luyện mô hình. Thứ ba, thay vì chỉ tập trung vào dữ liệu mới, người ta có thể cải thiện dữ liệu sẵn có thông qua làm sạch, tăng chất lượng, cân bằng dữ liệu hoặc tận dụng các mô hình đã được huấn luyện trước đó (transfer learning, fine-tuning)

[45].

Sau khi xác định và thu thập dữ liệu thì tiền xử lý dữ liệu là một trong những vấn đề quan trọng nhất trong quy trình ML. Dữ liệu được lấy trực tiếp từ nguồn có thể có sự không nhất quán, lỗi hoặc quan trọng nhất là chưa sẵn sàng để được xem xét cho quy trình khai thác dữ liệu. Hơn nữa, lượng dữ liệu ngày càng tăng trong các ứng dụng khoa học, công nghiệp và kinh doanh gần đây đòi hỏi phải có các công cụ phức tạp hơn để phân tích dữ liệu. Nhờ tiền xử lý dữ liệu, có thể biến đổi không thể thành có thể, điều chỉnh dữ liệu để đáp ứng nhu cầu đầu vào của từng thuật toán khai thác dữ liệu [46].

Tiền xử lý dữ liệu (Data Preprocessing) bao gồm nhiều bước quan trọng nhằm biến dữ liệu thô thành dữ liệu chất lượng, phù hợp cho việc khai thác và học máy. Trước hết, làm sạch dữ liệu (Data Cleaning) giúp xử lý các giá trị thiếu, làm mượt dữ liệu nhiễu, phát hiện hoặc loại bỏ các ngoại lai và giải quyết sự không nhất quán [47].

Tiếp theo, tích hợp dữ liệu (Data Integration) được thực hiện để kết hợp dữ liệu từ nhiều cơ sở dữ liệu, kho dữ liệu (data cubes) hoặc tệp tin khác nhau, tạo thành một nguồn dữ liệu thống nhất. Sau đó, chuyển đổi dữ liệu (Data Transformation) thông qua các kỹ thuật như chuẩn hóa và tổng hợp, nhằm đưa dữ liệu về dạng thích hợp cho phân tích. Giảm dữ liệu (Data Reduction) được áp dụng để tạo ra biểu diễn nhỏ gọn hơn về dữ liệu, nhưng vẫn giữ nguyên hoặc gần như nguyên vẹn ý nghĩa phân tích [47].

Cuối cùng, rời rạc hóa dữ liệu (Data Discretization) giúp chuyển đổi các thuộc tính liên tục thành dạng rời rạc, hỗ trợ nhiều thuật toán khai thác dữ liệu hoạt động hiệu quả hơn. Nhờ thực hiện đầy đủ các bước này, dữ liệu trở nên chính xác, nhất quán và tối ưu cho mô hình học máy [47].

Trong giai đoạn tiếp theo - Model Learning của vòng đời học máy, kỹ sư ML bắt đầu bằng việc lựa chọn loại mô hình phù hợp với vấn đề đặt ra (ví dụ: phân loại hay hồi quy), đồng thời cân nhắc khối lượng và cấu trúc dữ liệu huấn luyện cũng như kinh nghiệm thực tiễn. Sau đó, một hàm mất mát (loss function) được thiết lập để đo lường sai số trong quá trình huấn luyện, với mục tiêu giảm thiểu sai số này. Tiếp theo, cần xây dựng chiến lược sử dụng dữ liệu, bao gồm việc phân chia dữ liệu cho huấn luyện, kiểm định và thử nghiệm, hoặc áp dụng các phương pháp huấn luyện theo minibatch. Kỹ sư ML cũng chịu trách nhiệm lựa chọn siêu tham số (hyperparameters), vốn ảnh hưởng trực tiếp đến hiện tượng overfitting, underfitting và độ phức tạp của mô hình [48].

Ngoài ra, nếu có sẵn các mô hình đã huấn luyện thành công trong bối cảnh tương tự, transfer learning có thể được tận dụng để rút ngắn thời gian và nâng cao hiệu quả. Khi mô hình đạt mức hiệu suất mong muốn, tiến trình sẽ chuyển sang giai đoạn tiếp theo; ngược lại, cần quay lại khâu quản lý dữ liệu để bổ sung, làm giàu hoặc tiền xử lý dữ liệu nhằm cải thiện kết quả huấn luyện.

Ở bước *Model Selection*, kỹ sư ML lựa chọn loại mô hình, biến thể và cấu trúc phù hợp với yêu cầu bài toán. Các mô hình có thể bao gồm phân loại (classification) để xác định nhãn của dữ liệu đầu vào, hồi quy (regression) để dự đoán giá trị liên tục, phân cụm (clustering) để nhóm các đối tượng tương đồng, hoặc học tăng cường

(reinforcement learning) để tìm chính sách hành động tối ưu trong các bài toán điều khiển và lập kế hoạch [48].

Sau khi đã chọn mô hình, bước *Training* sẽ tiến hành tối ưu hóa hiệu năng của mô hình dựa trên một hàm mục tiêu phản ánh yêu cầu bài toán. Một phần tập dữ liệu huấn luyện được sử dụng để tìm ra các tham số bên trong (như trọng số trong mạng nơ-ron hoặc hệ số của đa thức) sao cho sai số được giảm thiểu. Phần dữ liệu còn lại (tập validation) sẽ được dùng để đánh giá khả năng tổng quát hóa của mô hình. Quá trình này thường lặp đi lặp lại nhiều lần, trong đó các siêu tham số (hyperparameters) được điều chỉnh sau mỗi vòng để tiếp tục cải thiện hiệu suất của mô hình [48].

Ở giai đoạn thứ ba là đánh giá mô hình (Model Verification). Mục tiêu trọng tâm ở giai đoạn này là bảo đảm mô hình đã huấn luyện có khả năng hoạt động tốt với dữ liệu mới chưa từng thấy trước đó, tức là đạt được khả năng khái quát hóa (generalization). Quá trình xác minh bao gồm các hoạt động nhằm cung cấp bằng chứng về khả năng này. Cụ thể, kiểm thử dựa trên dữ liệu được tiến hành bằng cách đánh giá mô hình với tập dữ liệu kiểm thử độc lập, được chuẩn bị từ giai đoạn Data Management. Tập này có thể tương đồng với dữ liệu huấn luyện nhưng cũng bao gồm các phần tử đặc biệt nhằm phục vụ mục đích xác minh, và không được phép dùng trong huấn luyện. Khi chạy mô hình trên dữ liệu kiểm thử, sai số khái quát (generalization error) sẽ được tính toán. Nếu sai số này vượt quá tiêu chí hiệu năng đã định, quy trình cần quay lại giai đoạn Data Management hoặc Model Learning để cải thiện mô hình [48].

Ngoài kiểm thử, giai đoạn này còn có thể sử dụng xác minh hình thức (formal verification) nhằm đảm bảo mô hình tuân thủ các thuộc tính hình thức quan trọng đã được mã hóa thành yêu cầu (chẳng hạn bằng kỹ thuật model checking hoặc chứng minh toán học). Nếu mô hình không đạt các yêu cầu này, quá trình cũng phải quay lại các giai đoạn trước để xử lý. Kết quả cuối cùng của giai đoạn này là bản tóm tắt kết quả xác minh, phản ánh mức độ đáp ứng yêu cầu của mô hình và quyết định việc mô hình có thể được tích hợp vào hệ thống hay không [48].

Và ở cuối quy trình này giai đoạn triển (Model Deployment) của vòng đời học máy, mô hình sau khi được kiểm chứng sẽ được tích hợp vào hệ thống cùng với các thành phần phần mềm khác phát triển theo phương pháp kỹ nghệ phần mềm truyền thống. Giai đoạn này bao gồm các hoạt động triển khai, giám sát hoạt động của mô hình và cập nhật định kỳ thông qua bảo trì ngoại tuyến hoặc học trực tuyến. Kết quả của giai đoạn triển khai là một hệ thống hoàn chỉnh, sẵn sàng hoạt động. Đặc biệt, trong các hệ thống quan trọng về an toàn, chẳng hạn hệ thống tự động hoặc tự thích nghi, ML đóng vai trò then chốt để đối phó với môi trường hoạt động năng động và bất định [48].

Nhìn chung, hệ thống sau khi hoàn thiện việc đánh giá từ phía người dùng đóng vai trò quan trọng. Ở bước này, các phản hồi được thu thập để kiểm chứng mức độ hài lòng và hiệu quả thực tế của hệ thống. Nếu các phản hồi cho thấy hệ thống chưa đủ tốt thì có thể quay trở lại các bước phía trước để cải thiện. Ngược lại, nếu phản hồi tích cực và hệ thống đạt yêu cầu đề ra, có thể xem dự án đã thành công và sẵn sàng đưa vào sử dụng chính thức.

1.1.6. Các vấn đề của học máy

Trong học máy, dữ liệu đóng vai trò then chốt bởi càng nhiều dữ liệu thì mô hình thường càng chính xác hơn. Tuy nhiên, việc thu thập dữ liệu lại tiêu tốn nhiều chi phí về tiền bạc, thời gian và công sức gán nhãn, trong khi không phải lúc nào cũng đảm bảo mang lại cải thiện đáng kể. Do đó, thách thức đặt ra là cần xác định bao nhiêu dữ liệu là đủ và thu thập như thế nào để đạt hiệu quả tối ưu với chi phí thấp nhất. Mục tiêu là tìm ra ngưỡng dữ liệu tối thiểu D^* để mô hình đạt hiệu suất mong muốn V^* , đồng thời tối ưu hóa quá trình thu thập để tránh tình trạng thu thập thừa gây lãng phí hoặc thiếu dẫn đến chất lượng mô hình kém. Để giải quyết vấn đề này, bài báo đề xuất quy trình Learn – Optimize – Collect (LOC) gồm ba bước: (1) Learn (Học): lấy mẫu từ dữ liệu hiện có, huấn luyện và đo lường hiệu suất để hình thành đường cong học tập; (2) Optimize (Tối ưu): sử dụng mô hình hồi quy để ước lượng yêu cầu dữ liệu tối thiểu, sau đó giải bài toán tối ưu nhằm xác định lượng dữ liệu cần bổ sung; và (3) Collect (Thu thập): bổ sung dữ liệu theo kế hoạch rồi lặp lại quá trình cho đến khi đạt mục tiêu hoặc hết số vòng cho phép. Các kỹ thuật hỗ trợ bao gồm hồi quy đường cong học tập (thường dùng dạng power law), bootstrap kết hợp với mô hình ước lượng mật độ xác suất (KDE, GMM), và giải bài toán tối ưu bằng gradient descent. Ngoài ra, LOC còn được mở rộng cho các tình huống nhiều nguồn dữ liệu khác nhau với hồi quy đa biến, nhằm cân bằng dữ liệu giữa các kênh. Các thí nghiệm trên nhiều tác vụ thực tế như phân loại ảnh, segmentation hay detection (CIFAR, ImageNet, VOC, BDD100K, nuScenes...) cho thấy LOC giúp giảm đáng kể tỷ lệ thất bại khi mô hình không đạt hiệu suất mục tiêu, đồng thời chi phí thu thập thấp hơn so với các phương pháp ước lượng truyền thống, và vẫn duy trì tính tổng quát trên nhiều loại dữ liệu cũng như bài toán khác nhau [49].

Chất lượng dữ liệu đào tạo có tác động rất lớn đến hiệu quả, độ chính xác và độ phức tạp của các tác vụ học máy. Dữ liệu vẫn dễ bị lỗi hoặc sai lệch trong quá trình thu thập, tổng hợp hoặc chú thích. Điều này đòi hỏi việc lập hồ sơ và đánh giá dữ liệu để hiểu rõ tính phù hợp của dữ liệu với các tác vụ học máy, và nếu không làm được điều này, dữ liệu có thể dẫn đến phân tích không chính xác và các quyết định không đáng tin cậy. Mặc dù các nhà nghiên cứu và chuyên gia đã tập trung vào việc cải thiện chất lượng mô hình, nhưng những nỗ lực nhằm cải thiện chất lượng dữ liệu vẫn còn hạn chế [50].

Việc đánh giá chất lượng dữ liệu qua các số liệu được thiết kế thông minh và phát triển các hoạt động chuyển đổi tương ứng để giải quyết các khoảng cách chất lượng giúp giảm bớt công sức của nhà khoa học dữ liệu trong việc gỡ lỗi lặp lại quy trình ML nhằm cải thiện hiệu suất mô hình. Hướng dẫn này nhấn mạnh tầm quan trọng của việc phân tích chất lượng dữ liệu xét về giá trị của nó đối với các ứng dụng ML. Việc tìm ra các vấn đề về chất lượng dữ liệu trong dữ liệu giúp các cá nhân khác nhau như người quản lý dữ liệu, nhà khoa học dữ liệu, chuyên gia về lĩnh vực hoặc nhà khoa học máy học có được những hiểu biết sâu sắc về dữ liệu và thực hiện các hành động khắc phục để khắc phục bất kỳ vấn đề nào. Hướng dẫn này khảo sát tất cả các phương pháp tiếp cận quan trọng liên quan đến chất lượng dữ liệu cho các lĩnh vực có cấu trúc, phi cấu trúc và không gian-thời gian đã được thảo luận trong các tài liệu, tập trung vào trực giác đằng sau chúng, làm nổi bật điểm mạnh và điểm tương

đồng của chúng, đồng thời minh họa khả năng ứng dụng của chúng vào các vấn đề thực tế. Cuối cùng, chúng ta sẽ thảo luận về công việc thú vị mà IBM Research đang thực hiện trong lĩnh vực này [50].

ML là công nghệ then chốt của trí tuệ nhân tạo, sử dụng mô hình dữ liệu học tập và huấn luyện để tìm ra bài toán nhằm đạt được quy luật. Trong các ứng dụng thực tế, luôn có sự khác biệt giữa dữ liệu đầu vào của mô hình và dữ liệu huấn luyện. Dựa trên dữ liệu huấn luyện bị sai lệch, hiện tượng quá khớp sẽ xảy ra, khiến học máy không đạt được mục tiêu mong đợi. Tổng quát hóa là quá trình đảm bảo mô hình có thể phản ánh đầy đủ các đặc điểm của dữ liệu đầu vào thực tế. Do đó, khả năng của mô hình học máy phụ thuộc phần lớn vào hiệu quả của việc tổng quát hóa. Để hiểu đầy đủ về mô hình học tập và tổng quát hóa, chúng tôi đã tiến hành nghiên cứu bằng phương pháp khớp đường cong đa thức. Đầu tiên, dựa trên dữ liệu huấn luyện, chúng tôi phân tích bằng lý thuyết ma trận và các giải pháp phân tích thu được từ phương pháp khớp đa thức. Sau đó, phân tích lý thuyết số và lý thuyết xác suất tối đa được thực hiện cho bài toán quá khớp. Cuối cùng, kết hợp với hàm mục tiêu, một phương pháp chính quy hóa điển hình để khắc phục hiện tượng quá khớp và cải thiện khả năng tổng quát hóa đã được xây dựng [51].


Độ phức tạp dữ liệu trong học máy phản ánh mức độ khó hay dễ của một bộ dữ liệu đối với việc huấn luyện mô hình, không chỉ phụ thuộc vào kích thước mà còn liên quan đến cấu trúc, sự phân bố, mức độ nhiễu và tính chồng lấn giữa các lớp. Khi dữ liệu có nhiều nhiễu, số chiều cao, ranh giới phân lớp phi tuyến hoặc số lượng mẫu quá nhỏ, mô hình sẽ gặp nhiều khó khăn trong việc học và dễ rơi vào tình trạng overfitting hoặc không khái quát được. Để đánh giá độ phức tạp, người ta sử dụng các thước đo khác nhau như độ chồng lấn đặc trưng, tính tuyến tính, phân tích lân cận hay các phương pháp dựa trên mạng lưới. Việc phân tích đúng độ phức tạp dữ liệu giúp lựa chọn mô hình học máy phù hợp, xác định nhu cầu thu thập dữ liệu hợp lý và nâng cao hiệu quả huấn luyện, đồng thời lý giải vì sao một số mô hình thất bại trong cùng một bộ dữ liệu [52].

Bảo trì dự đoán (Predictive Maintenance) là một chiến lược quan trọng nhằm đáp ứng nhu cầu ngày càng cao về việc giảm thiểu thời gian ngừng hoạt động và chi phí phát sinh trong quá trình vận hành. Một trong những thách thức chính của bảo trì dự đoán là xây dựng “chỉ số sức khỏe” – tức các thước đo định lượng phản ánh tình trạng của hệ thống liên quan đến một vấn đề bảo trì cụ thể, đồng thời xác định mối liên hệ giữa những chỉ số này với chi phí vận hành và rủi ro hỏng hóc. Phương pháp bảo trì dự đoán được đề xuất cho phép triển khai các quy tắc ra quyết định động trong quản lý bảo trì và có khả năng áp dụng cho dữ liệu đa chiều cũng như dữ liệu bị kiểm duyệt. Cách tiếp cận này hoạt động bằng cách huấn luyện nhiều mô-đun phân loại với các khoảng thời gian dự đoán khác nhau, từ đó tạo ra các mức đánh đổi giữa tần suất sự cố bất ngờ và tuổi thọ còn lại của thiết bị. Thông tin này sau đó được tích hợp vào hệ thống quyết định bảo trì dựa trên chi phí vận hành, nhằm mục tiêu tối ưu hóa và giảm thiểu tổng chi phí dự kiến [53].

Trong học máy, các vấn đề về minh bạch, quyền riêng tư và công bằng ngày càng trở nên quan trọng khi mô hình được ứng dụng rộng rãi trong tài chính, y tế, giao thông hay an toàn công cộng. Nhiều hệ thống học máy hoạt động như một “hộp

đen” khó giải thích, khiến người dùng không hiểu rõ lý do của các quyết định, từ đó làm giảm niềm tin và có thể dẫn đến những hệ quả tiêu cực như từ chối hồ sơ hợp lệ hay đưa ra quyết định thiên vị. Tuy nhiên, việc gia tăng mức độ minh bạch cũng có thể đi ngược lại quyền riêng tư, bởi các nghiên cứu cho thấy dự đoán của mô hình có thể bị khai thác để suy ra dữ liệu huấn luyện hoặc vô tình tiết lộ thông tin nhạy cảm. Đồng thời, thiếu minh bạch còn che giấu nguy cơ phân biệt đối xử đối với các nhóm xã hội khác nhau, chẳng hạn theo giới tính hoặc sắc tộc. Do đó, thách thức đặt ra là phải phát triển các phương pháp vừa đảm bảo mô hình có thể giải thích được, vừa bảo vệ dữ liệu cá nhân, đồng thời duy trì sự công bằng trong các quyết định tự động [54].

1.2. Tập dữ liệu



Hình 1.10 Biểu đồ dòng chảy hiển thị các loại dữ liệu

1.2.1. Các kiểu dữ liệu

Có bốn loại biến số: danh nghĩa (nominal), thứ bậc (ordinal), rời rạc (discrete), và liên tục (continuous). Hai loại đầu tiên được gọi là dữ liệu định tính (qualitative data), còn hai loại sau thuộc dữ liệu định lượng (quantitative data). Biến danh nghĩa và thứ bậc được đánh giá bằng từ ngữ hoặc thuộc tính → gọi là dữ liệu định tính. Biến rời rạc và liên tục thuộc về dữ liệu định lượng [56].

1.2.2. Các kiểu giá trị thuộc tính

Giá trị thuộc tính gồm hai nhóm chính: định tính và định lượng. Dữ liệu định tính phản ánh đặc điểm hay loại, có thể là danh nghĩa (không thứ tự), thứ bậc (có thứ tự), hoặc phân loại thành nhị phân và đa trị. Dữ liệu định lượng biểu diễn bằng số, gồm rời rạc (giá trị nguyên, dùng để đếm) và liên tục (có thể có thập phân, dùng để đo lường). Trong một số trường hợp, cùng một thuộc tính có thể được thể hiện dưới cả hai dạng tùy công cụ đo [57].

1.2.3. Kiểu thuộc tính liên tục và rời rạc

Trong tập dữ liệu, thuộc tính rời rạc (discrete) là những giá trị có thể đếm được và thường biểu diễn bằng số nguyên, chẳng hạn như số sinh viên trong lớp hoặc số lần xuất hiện của một sự kiện. Ngược lại, thuộc tính liên tục (continuous) có thể nhận vô số giá trị trong một khoảng, thường là kết quả đo lường như chiều cao, cân nặng hay nhiệt độ. Việc phân biệt hai loại này rất quan trọng vì nó quyết định cách mô tả dữ liệu, lựa chọn phép thống kê và hình thức trực quan hóa: dữ liệu rời rạc phù hợp với biểu đồ cột, còn dữ liệu liên tục thường được trình bày bằng biểu đồ tần suất (histogram) hoặc đường cong phân phối [58].

Biến số (Categorical variable)	Điều trị sớm (Early, n = 75)	Điều trị muộn (Late, n = 80)
Giới tính		
Nam (Male)	42% (32)	39% (31)
Thói quen		
Hút thuốc (Smokers)	28% (21)	31% (25)
Nguyên nhân chấn thương		
Tai nạn xe (Vehicle accident)	42% (32)	44% (35)
Té ngã (Fall)	38% (28)	42% (34)
Súng bắn (Gunshot wound)	13% (10)	9% (7)
Khác (Other)	7% (5)	5% (4)
Phân loại ASIA		
A	6% (5)	5% (4)
B	18% (14)	24% (19)
C	39% (29)	38% (30)
D	34% (25)	29% (23)
E	3% (2)	4% (3)

Bảng 1.1 Minh họa cách trình bày dữ liệu rời rạc khi so sánh 2 nhóm can thiệp

Thuộc tính (Continuous Variable)	Phẫu thuật (n = 75) Mean $\pm$ SD	Điều trị bảo tồn (n = 80) Mean $\pm$ SD
Tuổi (năm)	54.5 $\pm$ 9.4	51.9 $\pm$ 9.9
Chiều cao (cm)	175.0 $\pm$ 9.8	176.5 $\pm$ 9.9
Cân nặng (kg)	75.0 $\pm$ 13.0	75.4 $\pm$ 15.5
Thời gian mắc bệnh (năm)	2.3 $\pm$ 0.8	1.8 $\pm$ 0.7
Độ gập thân (độ)	102 $\pm$ 24.3	115 $\pm$ 29.7

Bảng 1.2 Minh họa cách hiển thị dữ liệu liên tục so sánh 2 biện pháp can thiệp.

1.2.4. Các đặc tính mô tả dữ liệu

Trung tâm và độ phân tán là những đặc tính cơ bản mô tả dữ liệu, giúp hình dung được xu hướng diễn hình và mức độ biến động. Các thước đo trung tâm phổ biến gồm mean, median và mode, trong khi độ phân tán thường được thể hiện qua range, variance, standard deviation (SD) và interquartile range (IQR). Ngoài ra, giá trị min–max lấy trực tiếp từ dữ liệu giúp nhận diện toàn bộ khoảng biến thiên. Về mặt trực quan, histogram thường được sử dụng để minh họa phân phối dữ liệu, từ đó người đọc dễ dàng nhận biết dữ liệu có đối xứng hay không, cũng như dạng phân phối đơn đỉnh hoặc đa đỉnh [59].

Hình dạng phân phối đóng vai trò quan trọng trong việc hiểu rõ bản chất của dữ liệu. Hai thước đo thường dùng là skewness và kurtosis. Skewness cho thấy mức độ lệch trái hay phải của phân phối, từ đó phản ánh sự cân bằng dữ liệu quanh trung tâm. Ngược lại, kurtosis đo lường độ nhọn của phân phối hoặc mức độ dày của phần đuôi so với phân phối chuẩn, giúp phát hiện các trường hợp dữ liệu có nhiều điểm ngoại biên hơn bình thường. [59][60].

Biểu đồ trực quan mang lại cái nhìn trực tiếp và dễ hiểu về dữ liệu. Boxplot thể hiện median, IQR, whiskers (thường lấy $\pm 1.5 \times \text{IQR}$) và các điểm ngoại biên, đồng thời cho phép đánh giá độ lệch qua hình dạng box và whiskers. Ngoài ra, violin plot là sự kết hợp giữa boxplot và kernel density, giúp biểu diễn rõ ràng hình dạng phân phối, đặc biệt hữu ích khi dữ liệu có nhiều mode. Violin plot không chỉ thể hiện median, IQR mà còn cung cấp thông tin về mật độ phân phối, cho phép phân tích sâu hơn so với boxplot truyền thống [61].

Công cụ phân tích nâng cao được áp dụng khi dữ liệu có đặc điểm phức tạp, chẳng hạn như phân phối đa đỉnh, lệch, hay bị cắt cụt. Trong những trường hợp này, các biểu đồ như ridgeline plot hoặc mirror density plot (MD plot) có thể được sử dụng để khám phá cấu trúc chi tiết hơn của dữ liệu. Những công cụ này cung cấp cái nhìn sâu sắc, trực quan và toàn diện hơn, từ đó giúp người phân tích hiểu rõ đặc tính tiềm ẩn cũng như mô hình hóa dữ liệu một cách chính xác hơn [62].

1.2.5. Trực quan hóa dữ liệu


Trực quan hóa dữ liệu là quá trình biến dữ liệu “khô khan” thành hình ảnh trực quan – biểu đồ, đồ thị, heatmap, scatter... để giúp người đọc nhanh chóng nhìn ra xu hướng, mẫu, mối quan hệ hoặc điểm bất thường trong tập dữ liệu (e.g., phát hiện

outlier, quan sát phân phối, so sánh nhóm ...) [63] [64].

Các chức năng và lợi ích chính: phát hiện mẫu, xu hướng, outliers dễ nhận diện các điểm ngoại lệ, cluster hay xu hướng trong dữ liệu ngay qua hình ảnh [63]. **Hỗ trợ truyền tải thông tin hiệu quả** visual hỗ trợ con người ghi nhớ, xử lý thông tin nhanh và chính xác hơn [65]. **Tối ưu theo nhiệm vụ** nghiên cứu chỉ ra hiệu quả của loại biểu đồ thay đổi theo từng tác vụ – ví dụ, pie chart dễ nhận thấy phần lớn nhất, scatter plot hữu ích để quan sát mối quan hệ giữa hai biến [66].

Nguyên tắc thiết kế trực quan hiệu quả (theo Tufte và nghiên cứu hiện đại) “Excellence in statistical graphics consists of complex ideas communicated with clarity, precision, and efficiency.” – biểu đồ phải **trực diện**, dễ hiểu và không gây nhầm lẫn. Ưu tiên “less is more”, nhất quán về màu & style, và phù hợp với ngữ cảnh dữ liệu. Tránh chartjunk – các hiệu ứng cầu kỳ, rườm rà gây rối mắt [67].

1.3. Tiền xử lý dữ liệu



Hình 1.11 Quy trình tiền xử lý dữ liệu

Tiền xử lý dữ liệu (data preprocessing) là một trong những bước quan trọng nhất trong khai phá dữ liệu và học máy. Quá trình này bao gồm nhiều giai đoạn như làm sạch dữ liệu (data cleaning), tích hợp dữ liệu (data integration), biến đổi dữ liệu (data transformation) và giảm bớt dữ liệu (data reduction). Làm sạch dữ liệu giúp loại bỏ nhiễu, xử lý dữ liệu thiếu hoặc không nhất quán; tích hợp dữ liệu cho phép hợp nhất thông tin từ nhiều nguồn khác nhau; biến đổi dữ liệu bao gồm chuẩn hóa, rời rạc hóa hoặc thay đổi dạng biểu diễn để phù hợp với thuật toán; trong khi đó, giảm bớt dữ liệu nhằm giảm kích thước dữ liệu nhưng vẫn giữ được thông tin quan trọng, giúp tăng hiệu quả tính toán của mô hình [70].

Theo Jiawei Han và cộng sự (2012) cho rằng dữ liệu thực tế thường không đầy đủ, nhiễu và không nhất quán, vì vậy tiền xử lý dữ liệu phải được xem là bước đầu tiên và quan trọng trong toàn bộ quy trình phát hiện tri thức từ cơ sở dữ liệu (KDD). Các công đoạn chính của quá trình này bao gồm làm sạch dữ liệu, tích hợp dữ liệu từ nhiều nguồn khác nhau, biến đổi dữ liệu thành định dạng phù hợp và giảm dữ liệu để loại bỏ thông tin dư thừa. Mỗi bước đều có vai trò quan trọng trong việc đảm bảo rằng dữ liệu đầu vào đáp ứng tốt yêu cầu của các thuật toán học máy [75].

Vào năm 2015, Salvador García và cộng sự đã nêu ra quan điểm của mình trong cuốn sách Data Preprocessing in Data Mining rằng tiền xử lý dữ liệu là một giai đoạn cơ bản và không thể bỏ qua trong học máy. Dữ liệu được lấy trực tiếp từ các nguồn thực tế thường tồn tại sự không nhất quán, sai sót hoặc quan trọng hơn là chưa sẵn sàng để sử dụng trong quá trình khai phá tri thức. Bên cạnh đó, sự gia tăng nhanh chóng về khối lượng dữ liệu trong các ứng dụng khoa học, công nghiệp và kinh doanh gần đây đòi hỏi sự xuất hiện của những công cụ và kỹ thuật xử lý ngày càng phức

tập. Nhờ có tiền xử lý dữ liệu, những thách thức này có thể được giải quyết, biến dữ liệu thô trở thành dữ liệu có cấu trúc và phù hợp, từ đó đáp ứng tốt các yêu cầu đầu vào của những thuật toán khai thác dữ liệu khác nhau [76].

1.3.1. Làm sạch dữ liệu

Làm sạch dữ liệu là một trong những bước cơ bản và quan trọng nhất trong quy trình tiền xử lý dữ liệu. Khi dữ liệu được thu thập từ nhiều nguồn khác nhau, thường sẽ tồn tại tình trạng thiếu giá trị, dữ liệu bị nhiễu hoặc có những ngoại lệ không phù hợp. Nếu không được xử lý, các vấn đề này sẽ ảnh hưởng trực tiếp đến độ chính xác của quá trình phân tích và mô hình học máy [71]. Do đó, làm sạch dữ liệu thường bao gồm nhiều công đoạn khác nhau và có vai trò như nền móng đảm bảo chất lượng cho các bước tiếp theo.

Trước hết, xử lý giá trị thiếu là một công việc thường gặp. Một số dữ liệu bị bỏ trống trong quá trình thu thập có thể dẫn đến sai lệch nếu không được bổ sung. Các phương pháp phổ biến là thay thế bằng trung bình, trung vị hoặc mode của thuộc tính. Ví dụ, với một thuộc tính X , giá trị còn thiếu có thể được điền bằng công thức:

$$x' = \frac{1}{n} \sum_{i=1}^n x_i$$

đây là cách điền giá trị trung bình, giúp giữ cho dữ liệu không bị lệch nhiều [75].

Tiếp theo, xử lý dữ liệu nhiễu cũng rất quan trọng. Dữ liệu nhiễu thường đến từ các lỗi đo lường hoặc nhập liệu, và nếu để nguyên sẽ làm giảm tính chính xác của mô hình. Một số phương pháp làm trơn dữ liệu được áp dụng như kỹ thuật binning (gom nhóm), hồi quy tuyến tính, hoặc các kiểm định thống kê. Mục tiêu là giữ lại xu hướng tổng thể thay vì những biến động ngẫu nhiên [72].

Một phần khác trong làm sạch dữ liệu là phát hiện và loại bỏ ngoại lệ. Ngoại lệ là những điểm dữ liệu khác biệt quá lớn so với phần còn lại, có thể do lỗi hoặc thực sự là các trường hợp đặc biệt. Để phát hiện ngoại lệ, có thể sử dụng chỉ số Z-score:

$$z = \frac{x - \mu}{\sigma}$$

Nếu $|z| > 3$, điểm dữ liệu thường được coi là ngoại lệ. Loại bỏ hoặc xử lý chúng sẽ giúp mô hình không bị méo mó trong quá trình huấn luyện [74].

Ngoài ra, chuẩn hóa dữ liệu cũng là một phần quan trọng để đảm bảo tính nhất quán. Khi các thuộc tính có thang đo khác nhau, chúng cần được đưa về cùng một khoảng giá trị. Một công thức phổ biến là Min-Max normalization:


$$x' = \frac{x - \min(X)}{\max(X) - \min(X)} * (new_max - new_min) + new_min$$

Nhờ vậy, các giá trị được đưa về một khoảng chuẩn như $[0,1]$, tránh hiện tượng một thuộc tính có giá trị lớn áp đảo những thuộc tính khác [75].


Cuối cùng, việc đồng nhất định dạng dữ liệu cũng rất cần thiết. Trong nhiều trường hợp, cùng một loại thông tin nhưng có thể được ghi nhận bằng nhiều cách khác nhau (ví dụ: "Nam", "Male", "M"), dẫn đến sự không nhất quán khi phân tích. Chuẩn hóa định dạng giúp cho tập dữ liệu trở nên thống nhất và dễ xử lý hơn [73].

Tóm lại, làm sạch dữ liệu không chỉ là bước chuẩn bị mà còn là một yếu tố then chốt quyết định đến độ tin cậy của mọi kết quả phân tích. Một tập dữ liệu sạch giúp cho các bước tiếp theo như tích hợp, biến đổi và giảm dữ liệu diễn ra thuận lợi và chính xác hơn [71].

1.3.2. Tích hợp dữ liệu



Hình 1.12 Quy trình tích hợp dữ liệu



Hình 1.13 Biểu đồ Effort ước lượng

Tích hợp dữ liệu là quá trình kết hợp dữ liệu từ nhiều nguồn khác nhau thành một tập thống nhất để phục vụ cho phân tích và khai thác thông tin. Trong thực tế, dữ liệu thường được lưu trữ ở nhiều hệ thống khác nhau, với định dạng, cấu trúc và mức độ chi tiết không đồng nhất. Nếu không có bước tích hợp phù hợp, dữ liệu có

thể bị phân mảnh, dẫn đến việc phân tích trở nên sai lệch hoặc thiếu toàn diện. Một trong những thách thức lớn trong tích hợp dữ liệu là sự khác biệt về lược đồ (schema heterogeneity), chẳng hạn như tên cột khác nhau nhưng biểu diễn cùng một thông tin, hoặc các kiểu dữ liệu không tương thích.


Ngoài ra, dung lượng dữ liệu lớn và sự trùng lặp thông tin giữa các nguồn cũng làm cho việc tích hợp trở nên phức tạp hơn. Việc loại bỏ các bản ghi trùng, đồng bộ hóa dữ liệu thời gian thực, hay hợp nhất các nguồn thông tin liên quan là những công việc tốn nhiều thời gian và công sức. Thực tế cho thấy, công đoạn tích hợp và làm sạch dữ liệu có thể chiếm tới 80% tổng khối lượng công việc trong các dự án quản lý dữ liệu. Điều này cho thấy, mặc dù thường bị đánh giá thấp, nhưng tích hợp dữ liệu lại có vai trò nền tảng trong đảm bảo chất lượng phân tích sau này [76].

Một trong những kỹ thuật phổ biến trong tích hợp dữ liệu là sử dụng ánh xạ lược đồ (schema mapping), cho phép xác định các mối quan hệ giữa các trường dữ liệu khác nhau. Ví dụ, một bảng ghi nhận thông tin “Họ tên” có thể được ánh xạ sang hai trường “First Name” và “Last Name” trong một hệ thống khác. Công thức ánh xạ đơn giản có thể mô tả như sau:

$$Integrated_Field = f(Source_1, Source_2, \dots, Source_n)$$

Trong đó, f là hàm ánh xạ hoặc quy tắc hợp nhất dữ liệu từ nhiều nguồn. Bên cạnh đó, các phương pháp dựa trên ngữ nghĩa (semantic integration) cũng được áp dụng, đặc biệt trong các hệ thống dữ liệu lớn và phức tạp. Việc sử dụng ontology hoặc từ điển dữ liệu giúp giảm thiểu xung đột ngữ nghĩa, đảm bảo rằng các thông tin giống nhau nhưng được diễn đạt khác nhau vẫn có thể được tích hợp chính xác [77][78].

1.3.3. Biến đổi dữ liệu



Hình 1.13 Quá trình chuẩn hóa dữ liệu

Biến đổi dữ liệu là bước chuyển dữ liệu thô sang dạng biểu diễn thuận lợi hơn cho mô hình, giúp tăng ổn định số liệu, giảm lệch thang đo và làm rõ cấu trúc tiềm ẩn. Thay vì “sửa lỗi” như ở bước làm sạch, giai đoạn này tập trung tái định dạng và tái tham số hóa. Một kỹ thuật nền tảng là chuẩn hóa theo Z-score, đưa mỗi thuộc tính về trung bình 0, độ lệch chuẩn 1 [79].

$$z = \frac{x - \mu}{\sigma}$$

Khi phân phối không chuẩn hoặc có ngoại lệ mạnh, có thể dùng chuẩn hóa bền vững (robust scaling) dựa trên trung vị và IQR:

$$y = \frac{x - \text{median}(X)}{IQR(X)}$$

Để xử lý phân phối lệch phải/đuôi dài, biến đổi logarit thường hữu ích, ví dụ $y = \log(x+1)$. Nếu cần linh hoạt hơn, dùng Box–Cox (áp dụng khi $x > 0$) [80]:

$$y = \begin{cases} x^\lambda - 1, & \lambda \neq 0 \\ \log x, & \lambda = 0 \end{cases}$$

hoặc Yeo–Johnson (xử lý được cả giá trị âm):

$$y = \begin{cases} \frac{(x^\lambda + 1)^\lambda - 1}{\lambda}, & x \geq 0, \lambda \neq 0 \\ \log(x + 1), & x \geq 0, \lambda = 0 \\ -\frac{(1 - x)^{2-\lambda} - 1}{2 - \lambda}, & x < 0, \lambda \neq 2 \\ -\log(x - 1), & x < 0, \lambda = 2 \end{cases}$$


Khi cần triệt tiêu ảnh hưởng của hình dạng phân phối, biến đổi theo bách phân/chuẩn hóa theo phân vị ánh xạ mỗi giá trị qua CDF thực nghiệm F rồi qua nghịch đảo chuẩn ϕ^{-1} : $y = \phi^{-1}(F(x))$; cách này đưa dữ liệu về gần chuẩn tắc và “cân bằng” đuôi. Với thuộc tính liên tục, rời rạc hóa tạo các khoảng $\tau_0 < \tau_1 < \dots < \tau_m$ và gán x vào khoảng k nếu $\tau_{k-1} \leq x < \tau_k$ (có thể chia đều độ rộng hoặc đều tần suất), giúp một số mô hình dựa trên luật/cây quyết định dễ học quy tắc. Ở mức cấu trúc, PCA tìm các vector riêng của ma trận hiệp phương sai [82].

$$C = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^\top$$

sau đó chiếu dữ liệu lên trục riêng chủ đạo: $y = W^\top(x - \mu)$ (cột của W là các eigenvectors tương ứng eigenvalues lớn nhất) để giảm chiều mà vẫn giữ phần lớn phương sai. Với dữ liệu phân loại, cần mã hóa: one-hot ánh xạ một hạng mục vào

vector đơn vị e_j ; khi số hạng mục lớn hoặc có quan hệ ngữ nghĩa, có thể dùng embedding (Word2Vec/GloVe/BERT) để biểu diễn mỗi nhãn bằng vector mật độ chiều thấp giàu ngữ nghĩa. Tùy miền bài toán, có thể kết hợp tổng hợp theo thời gian (ngày $\rightarrow$ tuần/tháng) nhằm làm nổi xu hướng và giảm nhiễu vi mô. Việc lựa chọn phép biến đổi phụ thuộc vào đặc tính phân phối, độ bền vững mong muốn và yêu cầu thuật toán; triển khai đúng sẽ giúp mô hình hội tụ ổn định, cải thiện khả năng khái quát và giảm chi phí tính toán [81].

1.3.4. Giảm bớt dữ liệu



Hình 1.14 Quá trình giảm dữ liệu

Trong các hệ thống dữ liệu lớn, số lượng bản ghi và số chiều dữ liệu có thể rất cao, gây áp lực cho việc lưu trữ cũng như xử lý. Giảm bớt dữ liệu (data reduction) là quá trình rút gọn kích thước nhưng vẫn giữ lại thông tin quan trọng, qua đó tăng tốc độ tính toán và tiết kiệm chi phí mà không làm mất nhiều độ chính xác. Đây là một bước quan trọng trong pipeline phân tích dữ liệu, đặc biệt trong bối cảnh big data, nơi mà tài nguyên lưu trữ và tính toán là hữu hạn [84].

Một kỹ thuật phổ biến là giảm chiều (dimensionality reduction). Trong đó, Phân tích thành phần chính (PCA) được ứng dụng rộng rãi để chiếu dữ liệu ban đầu sang một không gian con có ít chiều hơn nhưng vẫn giữ phần lớn phương sai. Biểu diễn toán học cơ bản:

$$Z = XW$$

trong đó X là ma trận dữ liệu gốc, W là ma trận vector riêng (eigenvectors), và Z là dữ liệu sau khi giảm chiều. Cách tiếp cận này cho phép loại bỏ các thành phần nhiễu và giữ lại thông tin cốt lõi [88].

Ngoài PCA, một hướng quan trọng khác là chọn thuộc tính (feature selection). Thay vì biến đổi dữ liệu, kỹ thuật này loại bỏ trực tiếp các đặc trưng kém giá trị. Một trong những thước đo phổ biến là Information Gain (IG)

$$IG(Class, Attribute) = H(Class) - H(Class | Attribute)$$

trong đó H là hàm entropy, phản ánh độ hỗn loạn của dữ liệu. Những thuộc tính mang lại mức IG cao sẽ được giữ lại để cải thiện hiệu quả mô hình [86][89].


Bên cạnh đó, sampling (lấy mẫu) được xem là một cách tiếp cận đơn giản nhưng hiệu quả. Chỉ cần chọn một tập con đủ đại diện từ dữ liệu gốc, hệ thống vẫn có thể huấn luyện và phân tích mà giảm đáng kể khối lượng tính toán [83]. Trong các hệ thống kho dữ liệu, kỹ thuật data cube aggregation cho phép thay thế dữ liệu chi tiết bằng các bảng tổng hợp ở nhiều mức độ, giúp trả lời truy vấn nhanh hơn mà không cần quét toàn bộ dữ liệu [85].

Đối với dữ liệu chuỗi thời gian hoặc tín hiệu, biến đổi wavelet (wavelet transform) cũng được dùng để nén dữ liệu, giữ lại các đặc trưng quan trọng ở miền tần số mà không cần lưu toàn bộ tín hiệu gốc [84].

Tóm lại, giảm bớt dữ liệu không chỉ đơn thuần là “nén” dữ liệu, mà còn giúp duy trì khả năng phân tích, tăng tốc độ huấn luyện mô hình, giảm chi phí lưu trữ và khai thác hiệu quả các hệ thống dữ liệu quy mô lớn [87].

1.3.5. Các giải pháp của quá trình tiền xử lý dữ liệu

Tiền xử lý dữ liệu (Data Preprocessing) được xem là một trong những công đoạn quan trọng nhất trong toàn bộ quy trình khai thác dữ liệu và học máy. Quy trình tiền xử lý dữ liệu bao gồm nhiều bước then chốt có mối liên hệ chặt chẽ với nhau. Có thể nói, tiền xử lý dữ liệu chính là cầu nối giữa dữ liệu thô và tri thức, đảm bảo rằng mọi bước khai thác sau đó đều được xây dựng trên một nền tảng dữ liệu chất lượng cao.



Hình 1.15 Các giải pháp của quá trình tiền xử lý dữ liệu

Giá trị bị thiếu, nhiễu và sự không nhất quán góp phần làm cho dữ liệu trở nên

không chính xác. Cho đến nay, các nhà nghiên cứu đã xem xét các kỹ thuật xử lý dữ liệu bị thiếu và làm mịn dữ liệu. Nhưng việc làm sạch dữ liệu là một công việc lớn đặt ra nhiều câu hỏi về việc người ta làm sạch dữ liệu bằng cách nào, có công cụ hỗ trợ hay không.

Dữ liệu bị thiếu (missing data) trong hầu hết các nghiên cứu thực tế, tình trạng dữ liệu bị thiếu (missing data) là điều khó tránh khỏi và có thể xuất hiện dưới nhiều hình thức khác nhau. Việc thiếu dữ liệu có thể bắt nguồn từ nhiều nguyên nhân như người tham gia khảo sát không trả lời hết bảng câu hỏi, một số trung tâm nghiên cứu không đo lường đầy đủ các biến, thiết bị hỏng hóc hoặc mẫu xét nghiệm thất lạc, Những nguyên nhân này không chỉ làm giảm chất lượng dữ liệu mà còn ảnh hưởng trực tiếp đến tính chính xác và độ tin cậy của kết quả phân tích [89]. Do đó, Vấn đề dữ liệu bị thiếu cần được giải quyết vì việc bỏ qua vấn đề này có thể gây ra sai lệch trong các mô hình đang được đánh giá và dẫn đến kết luận khai thác dữ liệu không chính xác [90].

Có nhiều phương pháp khác nhau để xử lý dữ liệu bị thiếu, và mỗi cách đều có những ưu nhược điểm riêng. Cách đơn giản nhất là bỏ qua bộ dữ liệu (Ignore the tuple) khi giá trị bị thiếu, tuy nhiên điều này thường kém hiệu quả nếu tỷ lệ dữ liệu thiếu cao. Một lựa chọn khác là điền thủ công (Fill in manually), nhưng phương pháp này mất nhiều thời gian và hầu như không khả thi với các tập dữ liệu lớn. Ta cũng có thể thay thế bằng một hằng số chung (Global constant) như “Không xác định”, cách này dễ thực hiện nhưng lại có nguy cơ gây sai lệch trong phân tích. Một giải pháp phổ biến hơn là dùng các thước đo xu hướng trung tâm (Mean/Median imputation) như trung bình hoặc trung vị để lấp vào chỗ trống, tùy theo đặc điểm phân phối dữ liệu [75].

Trong nhiều trường hợp, việc sử dụng giá trị trung bình hoặc trung vị trong cùng một lớp dữ liệu (Class-based mean/median imputation) sẽ phản ánh đặc trưng của nhóm tốt hơn. Cuối cùng, phương pháp tiên tiến nhất là dự đoán giá trị còn thiếu dựa trên các mô hình thống kê hoặc học máy (Predictive imputation / Regression / Bayesian inference / Decision tree), vốn khai thác thông tin từ các thuộc tính khác để đưa ra ước lượng hợp lý hơn. Dù các phương pháp này đều tiềm ẩn khả năng làm sai lệch dữ liệu, nhưng cách tiếp cận dựa trên mô hình thường được đánh giá cao nhờ khả năng bảo toàn tốt hơn mối quan hệ giữa các biến [75].

Trong quá trình nghiên cứu, việc đánh giá khả năng sai lệch (bias) do dữ liệu bị thiếu là một yêu cầu quan trọng. Khi không có thông tin về những đối tượng không phản hồi trong khảo sát, rất khó để xác định mức độ sai lệch có thể xảy ra, do đó một tỷ lệ phản hồi cao được xem là điều kiện cần thiết nhằm đảm bảo độ tin cậy của kết quả. Tuy nhiên, trong một số trường hợp, có thể khai thác thêm thông tin từ nguồn dữ liệu ban đầu. Chẳng hạn, nếu mẫu khảo sát được lựa chọn từ cơ sở dữ liệu có sẵn thông tin về các đặc điểm nhân khẩu học như tuổi và giới tính, việc so sánh giữa nhóm trả lời và nhóm không trả lời trên các biến này sẽ cung cấp cơ sở đánh giá tính đại diện của mẫu [89].

Nhiều dữ liệu (noise data) trong dữ liệu được hiểu là sai số ngẫu nhiên hoặc sự biến thiên bất thường trong các biến đo lường. Các kỹ thuật thống kê cơ bản như boxplot hay scatter plot, cùng với các phương pháp trực quan hóa dữ liệu, thường

được sử dụng để phát hiện các giá trị ngoại lai (outliers), vốn có thể là biểu hiện của nhiễu [75]. Để loại bỏ hoặc giảm thiểu ảnh hưởng của nhiễu, một số phương pháp làm mượt dữ liệu thường được áp dụng. Các bài toán có nhiễu thường được xem là thách thức lớn trong phân tích và khai thác dữ liệu. Nếu mô hình hoặc phương pháp được sử dụng quá nhạy cảm với nhiễu, khả năng đưa ra giải pháp chính xác sẽ bị hạn chế. Do đó, việc áp dụng các kỹ thuật chuyên biệt nhằm phát hiện, giảm thiểu và xử lý nhiễu là hết sức cần thiết. Tuy nhiên, xác định nhiễu lại là một nhiệm vụ phức tạp, bởi không phải lúc nào cũng có thể phân biệt rõ ràng giữa dữ liệu hợp lệ nhưng hiếm gặp và dữ liệu thực sự là sai số [91].

Trong đó, binning là kỹ thuật phổ biến, thực hiện bằng cách sắp xếp dữ liệu và chia thành các nhóm (bin) có kích thước bằng nhau hoặc số lượng phần tử bằng nhau. Các giá trị trong bin có thể được thay thế bằng trung bình, trung vị hoặc giá trị biên, qua đó giúp dữ liệu trở nên ổn định hơn và giảm tác động của các biến động nhỏ. Ngoài ra, dữ liệu còn có thể được làm mượt thông qua hồi quy (regression) bằng cách khớp dữ liệu với một hàm số, chẳng hạn hồi quy tuyến tính để biểu diễn mối quan hệ giữa hai biến, hoặc hồi quy đa biến khi có nhiều thuộc tính liên quan. Một hướng tiếp cận khác là phân tích ngoại lai (outlier analysis), trong đó kỹ thuật phân cụm (clustering) được dùng để nhóm các giá trị tương đồng lại với nhau, còn những giá trị nằm ngoài cụm có thể được coi là ngoại lai [75].

Các phương pháp này không chỉ giúp phát hiện và xử lý nhiễu mà còn góp phần nâng cao độ chính xác và độ tin cậy của các phân tích dữ liệu [75]. Nhiễu là một vấn đề gần như không thể tránh khỏi trong quá trình thu thập và chuẩn bị dữ liệu, đặc biệt trong các ứng dụng khai thác dữ liệu, nơi sai sót thường xuyên xuất hiện. Chất lượng của dữ liệu huấn luyện đóng vai trò then chốt, bởi hiệu suất của các mô hình học máy không chỉ phụ thuộc vào bản thân thuật toán mà còn vào mức độ dữ liệu bị ảnh hưởng bởi nhiễu. Khi dữ liệu chứa nhiều sai số ngẫu nhiên hoặc giá trị bất thường, việc xây dựng mô hình trở nên phức tạp hơn, đồng thời độ tin cậy và tính chính xác của kết quả cũng giảm đáng kể [91].

Dữ liệu không nhất quán (Inconsistent Data) trong nhiều bài toán khoa học vật lý, việc ước lượng các tham số chưa biết thường dựa trên mối quan hệ tuyến tính hoặc bán tuyến tính với một tập dữ liệu thực nghiệm. Tuy nhiên, dữ liệu này có thể bị ảnh hưởng bởi các lỗi ngẫu nhiên, sự thiếu hụt dữ liệu cần thiết để xác định các ẩn số, sự dư thừa thông tin, hoặc thậm chí kết hợp của tất cả các yếu tố trên. Những vấn đề này dẫn đến tình trạng dữ liệu không nhất quán, gây khó khăn cho quá trình phân tích và làm giảm độ tin cậy của kết quả mô hình [92].

Để xử lý dữ liệu không nhất quán theo cách thủ công, người ta thường sử dụng các tham chiếu bên ngoài (external references) và các công cụ kỹ thuật tri thức (knowledge engineering tools), chẳng hạn như quy trình kỹ thuật tri thức. Những công cụ này giúp so sánh, đối chiếu dữ liệu với nguồn đáng tin cậy và áp dụng các quy tắc hoặc tri thức chuyên ngành để phát hiện, hiệu chỉnh và duy trì tính nhất quán của dữ liệu.

Trong bối cảnh tích hợp dữ liệu từ nhiều nguồn khác nhau, một thách thức lớn là xung đột giá trị dữ liệu (data value conflicts). Cùng một thực thể trong thế giới thực có thể được mô tả bằng các giá trị thuộc tính khác nhau, do khác biệt về cách

biểu diễn, đơn vị đo lường hoặc phương pháp mã hóa. Ngoài ra, sự khác biệt về mức độ trừu tượng cũng có thể dẫn đến sai lệch, chẳng hạn một hệ thống ghi nhận doanh thu tổng cho một chi nhánh, trong khi hệ thống khác ghi nhận cho toàn bộ khu vực. Những trường hợp này khiến việc tích hợp và phân tích trở nên phức tạp. Vì vậy, phát hiện và xử lý dữ liệu không nhất quán là bước thiết yếu trong quy trình làm sạch dữ liệu, nhằm nâng cao chất lượng, đảm bảo tính chính xác và tăng giá trị sử dụng cho các phân tích sau này [75].

Dữ liệu không nhất quán là một thách thức quan trọng trong quá trình tích hợp và phân tích dữ liệu, đặc biệt khi dữ liệu được thu thập từ nhiều nguồn hoặc hệ thống khác nhau. Sự không nhất quán có thể dẫn đến sai lệch kết quả, làm giảm độ tin cậy của mô hình và gây khó khăn trong việc truy vấn cũng như khai thác tri thức. Do đó, việc phát hiện và xử lý dữ liệu không nhất quán không chỉ giúp nâng cao chất lượng dữ liệu mà còn đảm bảo tính chính xác và ý nghĩa của các phân tích sau này [93].

Như đã trình bày ở mục 1.3.4, các phương pháp giảm thiểu dữ liệu bao gồm giảm số chiều, giảm số lượng và nén dữ liệu. Các phương pháp này giúp rút gọn dữ liệu nhưng vẫn giữ lại những đặc trưng quan trọng, từ đó nâng cao hiệu quả trong quá trình xử lý và khai thác dữ liệu.

Giảm chiều dữ liệu (Dimensionality Reduction) là quá trình giảm số lượng biến ngẫu nhiên hoặc thuộc tính cần xem xét trong tập dữ liệu. Các phương pháp phổ biến bao gồm biến đổi wavelet và phân tích thành phần chính (PCA), giúp chiếu dữ liệu gốc vào không gian nhỏ hơn nhưng vẫn giữ được thông tin quan trọng. Ngoài ra, lựa chọn tập con thuộc tính (Attribute Subset Selection) cũng được sử dụng để loại bỏ những thuộc tính không liên quan, ít liên quan hoặc dư thừa, qua đó đơn giản hóa dữ liệu mà vẫn duy trì giá trị phân tích [75].

Giảm số lượng dữ liệu (Numerosity Reduction) tập trung vào việc thay thế dữ liệu gốc bằng các dạng biểu diễn nhỏ gọn hơn. Các kỹ thuật này có thể là tham số (parametric), trong đó một mô hình được xây dựng để ước lượng dữ liệu và chỉ cần lưu trữ các tham số thay vì toàn bộ dữ liệu (ví dụ: hồi quy, mô hình log-linear). Ngoài ra, các phương pháp phi tham số (non-parametric) cũng được sử dụng, như biểu đồ tần suất (histograms), phân cụm (clustering), lấy mẫu (sampling) và tổng hợp khối dữ liệu (data cube aggregation) [75].

Nén dữ liệu (Data Compression) là một hướng tiếp cận khác, trong đó dữ liệu được biến đổi để tạo ra dạng biểu diễn nhỏ gọn hơn. Nếu dữ liệu gốc có thể được tái tạo hoàn toàn từ dữ liệu nén mà không mất thông tin, đó là nén không mất dữ liệu (lossless); ngược lại, nếu chỉ có thể tái tạo gần đúng, đó là nén mất dữ liệu (lossy). Các thuật toán nén chuỗi không mất dữ liệu đã được áp dụng rộng rãi, mặc dù chúng thường hạn chế khả năng thao tác dữ liệu. Cần lưu ý rằng các kỹ thuật giảm chiều và giảm số lượng dữ liệu cũng có thể được coi là một dạng nén dữ liệu. Tuy nhiên, thời gian tính toán cho việc giảm dữ liệu không nên vượt quá lợi ích tiết kiệm thời gian mang lại khi khai thác dữ liệu đã được giảm kích thước [75].

Nhìn chung các phương pháp tiền xử lý dữ liệu giữ vai trò quan trọng trong việc đảm bảo chất lượng dữ liệu trước khi đưa vào các thuật toán khai thác. Mỗi phương pháp đều có ưu điểm và hạn chế riêng: làm sạch dữ liệu giúp loại bỏ nhiễu và giá trị

thiếu nhưng có thể làm mất thông tin nếu áp dụng không cẩn thận; chuẩn hóa và biến đổi dữ liệu giúp thống nhất định dạng, song lại tốn thời gian khi dữ liệu đa dạng; giảm chiều và nén dữ liệu giúp tiết kiệm bộ nhớ và tăng tốc độ xử lý, tuy nhiên có nguy cơ làm mất đi những đặc trưng quan trọng; trong khi đó, lựa chọn trường hợp mang tính “thông minh” hơn so với lấy mẫu ngẫu nhiên vì vừa giảm kích thước vừa giữ lại tính đại diện của dữ liệu. Nhìn chung, việc áp dụng linh hoạt và kết hợp nhiều kỹ thuật tiền xử lý sẽ mang lại tập dữ liệu tối ưu, vừa gọn nhẹ vừa đảm bảo hiệu năng cho quá trình khai thác và học máy.

1.4. Đánh giá hiệu năng trong học máy

Đánh giá hiệu suất là một bước quan trọng trong quá trình học máy, đặc biệt khi ứng dụng vào các lĩnh vực nhạy cảm như xạ trị ung thư, nơi tính chính xác và độ tin cậy đóng vai trò quyết định hay lĩnh vực đặc thù khác. Đây là một nhiệm vụ phức tạp, đòi hỏi sự thận trọng và sử dụng các phương pháp đánh giá phù hợp. Việc lựa chọn và áp dụng đúng đắn các kỹ thuật đánh giá là yếu tố then chốt để đảm bảo chất lượng và giá trị thực tiễn của mô hình học máy.

Hiệu năng của hệ thống học máy không chỉ phụ thuộc vào bản thân giải thuật mà còn bị chi phối bởi nhiều yếu tố khác. Một trong những yếu tố quan trọng là phân bố lớp (class distribution), vì sự mất cân bằng giữa các lớp có thể làm mô hình thiên lệch trong dự đoán. Bên cạnh đó, chi phí của việc phân loại sai (cost of misclassification) cũng đóng vai trò then chốt, đặc biệt trong các bài toán quan trọng như y tế hay tài chính, nơi một lỗi nhỏ có thể dẫn đến hậu quả nghiêm trọng. Ngoài ra, kích thước của tập huấn luyện (size of the training set) ảnh hưởng trực tiếp đến khả năng học và khái quát hóa của mô hình, trong khi kích thước của tập kiểm thử (size of the testing set) lại quyết định mức độ tin cậy khi đánh giá hiệu suất của hệ thống. Do đó, để đảm bảo chất lượng và độ chính xác, cần xem xét tổng thể tất cả các yếu tố này song song với việc lựa chọn giải thuật học máy phù hợp.

1.4.1. Các loại bài toán áp dụng

Phân loại (Classification) là một phương pháp học có giám sát trong học máy, được xem như một bài toán dự đoán, trong đó mô hình cần xác định nhãn lớp cho một đối tượng cụ thể. Về mặt toán học, quá trình này được mô tả bằng một hàm ánh xạ f từ tập biên đầu vào X sang tập biên đầu ra Y , dưới dạng các mục tiêu, nhãn hoặc danh mục. Quá trình dự đoán có thể được thực hiện trên cả dữ liệu có cấu trúc lẫn dữ liệu phi cấu trúc. Tuy nhiên, các mô hình phân loại thường gặp khó khăn khi xử lý các tập dữ liệu mất cân bằng, nơi một lớp chiếm ưu thế vượt trội so với các lớp khác, dẫn đến nguy cơ sai lệch trong dự đoán khi mô hình có xu hướng thiên về lớp phổ biến và bỏ qua lớp hiếm [95].

Các loại bài toán phân loại phổ biến: phân loại nhị phân, phân loại đa lớp và phân loại đa nhãn. Phân loại nhị phân là trường hợp chỉ có hai nhãn lớp, thường biểu diễn trạng thái “có/không” hoặc “đúng/sai”. Phân loại đa lớp mở rộng hơn khi có nhiều hơn hai nhãn lớp, trong đó mỗi ví dụ được gán vào đúng một lớp trong tập hợp cho trước, chẳng hạn như tập dữ liệu NSL-KDD phân chia các kiểu tấn công mạng thành bốn lớp: DoS, U2R, R2L và Probing. Trong khi đó, phân loại đa nhãn cho phép một ví dụ có thể đồng thời thuộc nhiều nhãn, được xem là sự khái quát của phân loại

đa lớp [95].

Để giải quyết các dạng bài toán phân loại khác nhau, nhiều thuật toán đã được đề xuất trong học máy, mỗi thuật toán có những đặc điểm, ưu điểm và hạn chế riêng, phù hợp với từng loại dữ liệu và mục tiêu ứng dụng cụ thể như: Naive Bayes (NB), Hồi quy Logistic (LR), K-Nearest Neighbors (KNN), Máy vector hỗ trợ (SVM), ... Hiệu năng của các thuật toán này thường được đánh giá thông qua các chỉ số như Accuracy (độ chính xác tổng thể), Precision (độ chính xác theo lớp), Recall (khả năng bao phủ), F1-Score (trung hòa giữa Precision và Recall), và AUC-ROC (khả năng phân biệt giữa các lớp).

Naive Bayes (NB) là một thuật toán phân loại dựa trên định lý Bayes, với giả định rằng các đặc trưng là độc lập có điều kiện với nhau. Thuật toán này có khả năng hoạt động tốt trong nhiều tình huống thực tế, chẳng hạn như phân loại văn bản hay lọc thư rác, và có thể áp dụng cho cả bài toán phân loại nhị phân lẫn đa lớp. Điểm mạnh nổi bật của NB là chỉ cần một lượng nhỏ dữ liệu huấn luyện để ước lượng các tham số cần thiết, nhờ vậy việc huấn luyện diễn ra nhanh chóng và đơn giản hơn so với nhiều phương pháp phức tạp khác [95].

$$p(c|E) = \frac{p(E|c)p(c)}{p(E)}$$

Trong đó: $p(c|E)$: Xác suất hậu nghiệm (*posterior probability*)

$p(E|c)$: Xác suất có điều kiện (*likelihood*)

$p(c)$: Xác suất tiên nghiệm (*prior probability*)

$p(E)$: Hệ số chuẩn hóa (*evidence hoặc marginal probability*)

Hồi quy Logistic (Logistic Regression - LR) là một trong những mô hình thống kê xác suất phổ biến và được ứng dụng rộng rãi trong các bài toán phân loại của học máy. Phương pháp này sử dụng hàm logistic (sigmoid) để ước lượng xác suất và ánh xạ đầu ra về khoảng $[0,1]$ giúp mô hình dự đoán khả năng một mẫu thuộc về một lớp cụ thể. Hồi quy Logistic thường cho hiệu quả tốt khi dữ liệu có thể tách tuyến tính, tuy nhiên lại dễ gặp hiện tượng overfitting với các tập dữ liệu có số chiều lớn. Mặc dù có thể được mở rộng cho cả bài toán hồi quy và phân loại, nhưng trên thực tế thuật toán này được sử dụng nhiều hơn cho các bài toán phân loại [95].

$$g(z) = \frac{1}{1 + e^{-z}}$$

KNN là một trong những thuật toán học có giám sát đơn giản và phổ biến nhất trong khai phá dữ liệu và học máy. Thuật toán K-Nearest Neighbors (KNN) dựa trên giả định rằng các mẫu dữ liệu nằm gần nhau trong không gian đặc trưng thường có

cùng nhãn. Khi cần phân loại một mẫu mới, KNN sẽ tính toán độ tương đồng (thường bằng khoảng cách Euclid, Manhattan hoặc các thước đo khác) giữa mẫu này với toàn bộ các mẫu trong tập huấn luyện. Sau đó, thuật toán chọn ra K mẫu láng giềng gần nhất và tiến hành gán nhãn cho mẫu mới dựa trên nguyên tắc bỏ phiếu đa số (trong bài toán phân loại) hoặc tính giá trị trung bình (trong bài toán hồi quy) [96].

Công thức tổng quát:

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{\frac{1}{p}}$$

Trong đó p là một tham số, n là số chiều (thuộc tính) và x_i và y_i lần lượt là thuộc tính (thành phần) thứ i của các đối tượng dữ liệu x và y.

Ngoài ra còn nhiều thuật toán phổ biến khác như: máy Vector Hỗ Trợ (Support Vector Machine - SVM), cây quyết định (Decision Tree - DT) và rừng ngẫu nhiên (Random Forest - RF) cũng rất phổ biến trong phân loại. Support Vector Machine là một trong những phương pháp mạnh mẽ và được sử dụng rộng rãi. Ý tưởng cốt lõi của SVM là tìm một siêu phẳng (hyperplane) tối ưu để phân tách các lớp dữ liệu trong không gian đặc trưng, sao cho khoảng cách từ siêu phẳng đến các điểm dữ liệu gần nhất của mỗi lớp (margin) là lớn nhất. Cây quyết định phân tách dữ liệu dựa trên các thuộc tính theo nguyên tắc tối đa hóa thông tin thu được hoặc giảm thiểu độ hỗn loạn (entropy). Rừng ngẫu nhiên là sự mở rộng của cây quyết định, sử dụng tập hợp nhiều cây huấn luyện trên các mẫu dữ liệu khác nhau và kết hợp kết quả dự đoán theo nguyên tắc bỏ phiếu đa số, giúp tăng độ chính xác và giảm overfitting [95].

Hồi quy (Regression), tương tự như phân loại, cũng nhằm dự đoán một biến mục tiêu cho từng điểm dữ liệu hoặc cá thể. Tuy nhiên, khác với phân loại vốn tập trung vào các biến rời rạc, hồi quy chủ yếu được áp dụng cho những bài toán liên quan đến biến liên tục. Mặc dù các mô hình hồi quy có khả năng nắm bắt những mối quan hệ phức tạp giữa các biến đầu vào và biến đầu ra, chúng thường nhạy cảm với các **giá trị ngoại lai**, vốn có thể làm sai lệch kết quả và ảnh hưởng đến độ tin cậy của dự đoán [97]. Các mô hình hồi quy hiện được sử dụng rộng rãi trong nhiều lĩnh vực, bao gồm dự báo hoặc dự đoán tài chính, ước tính chi phí, phân tích xu hướng, tiếp thị, ước tính chuỗi thời gian, mô hình phản ứng thuốc và nhiều lĩnh vực khác [95].

Một số thuật toán hồi quy tiêu biểu bao gồm: hồi quy tuyến tính đơn và đa biến (Simple & Multiple Linear Regression), mô hình hóa mối quan hệ tuyến tính giữa biến đầu ra và một hay nhiều biến đầu vào; hồi quy đa thức (Polynomial Regression), mở rộng hồi quy tuyến tính để mô tả quan hệ phi tuyến bằng đa thức bậc cao; và hồi quy LASSO cùng Ridge (L1 & L2 Regularization Regression), được sử dụng nhằm giảm hiện tượng quá khớp và xử lý khi dữ liệu có nhiều đặc trưng, trong đó LASSO có khả năng chọn lọc đặc trưng bằng cách triệt tiêu các hệ số không quan trọng, còn Ridge giúp ổn định mô hình trong trường hợp các biến độc lập có tương quan cao. Các thuật toán này đều đóng vai trò quan trọng trong việc xây dựng mô hình dự đoán và phân tích dữ liệu trong nhiều lĩnh vực ứng dụng khác nhau [95].

Hiệu năng của các mô hình hồi quy thường được đánh giá bằng các chỉ số như MSE, RMSE, MAE và R^2 , cho phép so sánh và lựa chọn mô hình phù hợp với dữ liệu thực tế.

Mean Absolute Error (MAE) là một phương pháp phổ biến để đo lường sai số trung bình tuyệt đối giữa giá trị dự đoán và giá trị thực tế. MAE phản ánh mức độ sai lệch trung bình tuyệt đối, với giá trị càng nhỏ thì mô hình càng chính xác. MAE được định nghĩa theo công thức [97]:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - x_i|$$

Trong đó: x_i : giá trị dự đoán thứ i

y_i : giá trị thực tế thứ i

n : số lượng điểm dữ liệu

Root Mean Squared Error (RMSE) là một chỉ số thường được sử dụng để đo lường sai số trung bình giữa giá trị dự đoán và giá trị thực tế trong các bài toán hồi quy. RMSE phản ánh mức độ sai lệch trung bình bình phương có căn bậc hai, nhờ đó nhạy cảm hơn với các sai số lớn so với MAE. Giá trị RMSE càng nhỏ chứng tỏ mô hình dự đoán càng chính xác. Chỉ số này được định nghĩa như sau [97]:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - x_i)^2}$$

Trong đó: x_i : giá trị dự đoán thứ i

y_i : giá trị thực tế thứ i

n : số lượng điểm dữ liệu

Tương tự như MAE, đơn vị của RMSE giống với đơn vị được sử dụng cho các điểm dữ liệu. Tuy nhiên, RMSE nhạy cảm hơn với các giá trị ngoại lai so với MAE [97].

R-squared (R^2), hay còn gọi là hệ số xác định (coefficient of determination), là một thước đo thể hiện tỷ lệ phương sai của biến mục tiêu (target variable) được giải thích bởi mô hình hồi quy. Không giống như MAE và RMSE, lỗi R^2 không được đo bằng cùng đơn vị với các điểm dữ liệu mà thay vào đó thay đổi từ 0 (mô hình giải thích 0% phương sai của biến mục tiêu) đến 1 (mô hình giải thích 100% phương sai của biến mục tiêu). R^2 được định nghĩa bởi công thức [97]:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - x_i)^2}{\sum_{i=1}^n (y_i - y_{mean})^2}$$

Trong đó: x_i : giá trị dự đoán thứ i

y_i : giá trị thực tế thứ i

n : số lượng điểm dữ liệu

y_{mean} : giá trị trung bình của các y_i

1.4.2. Các cách đánh giá hiệu năng và cách thực hiện chúng

Phương pháp holdout là một trong những kỹ thuật đánh giá mô hình đơn giản và phổ biến trong lĩnh vực học đôi khi còn được gọi là ước lượng theo mẫu kiểm thử (test sample estimation), sẽ phân chia dữ liệu thành hai tập con loại trừ nhau: tập huấn luyện và tập kiểm thử [98]. Thông thường, khoảng hai phần ba dữ liệu được sử dụng cho quá trình huấn luyện và một phần ba còn lại được sử dụng cho việc kiểm thử. Tập huấn luyện có nhiệm vụ xây dựng mô hình, trong khi tập kiểm thử dùng để đánh giá hiệu năng của mô hình sau khi huấn luyện.

Một điểm quan trọng là dữ liệu trong tập kiểm thử không được phép tham gia vào quá trình huấn luyện và ngược lại. Do chỉ một phần dữ liệu được dùng để xây dựng mô hình nên kết quả đánh giá bằng phương pháp holdout thường có xu hướng bi quan. Tuy nhiên, cách tiếp cận này vẫn được xem là phù hợp và hiệu quả khi kích thước tập dữ liệu đủ lớn [95].

Gọi D_h là tập holdout, là một tập con của D có kích thước h , và gọi D_t là $D \setminus D_h$. Độ chính xác ước lượng theo phương pháp holdout được định nghĩa như sau [98]:

$$acc_h = \frac{1}{h} \sum_{(v_i, y_i) \in D_h} \delta(I(D_t, v_i), y_i)$$

Trong đó $\delta(i, j) = 1$ nếu $i = j$, và 0 trong các trường hợp khác.

Phương pháp holdout có nhược điểm là kết quả ước lượng độ chính xác phụ thuộc mạnh vào cách chia dữ liệu thành tập huấn luyện và tập kiểm thử, do đó kết quả thường mang tính ngẫu nhiên. Trong các tình huống dữ liệu được chia không cân đối, một số lớp có thể bị đại diện quá nhiều trong tập huấn luyện nhưng lại quá ít trong tập kiểm thử, dẫn đến ước lượng độ chính xác bị sai lệch [98].

Phương pháp Repeated Hold-out được xây dựng trên nền tảng của hold-out cơ bản, nhưng thay vì chỉ chia dữ liệu một lần duy nhất, quá trình này được lặp lại nhiều lần với các phép chia ngẫu nhiên khác nhau giữa tập huấn luyện và tập kiểm tra. Ở mỗi lần lặp, một tỷ lệ cố định của tập dữ liệu được chọn ngẫu nhiên để tạo thành tập huấn luyện, phần còn lại làm tập kiểm tra. Các giá trị đánh giá hiệu năng (ví dụ độ chính xác, sai số, F1-score, ...) được ghi nhận qua từng lần lặp và sau đó tính trung bình để đưa ra ước lượng tổng thể. Cách tiếp cận này giúp giảm sự phụ

thuộc vào một phép chia dữ liệu duy nhất, từ đó cung cấp kết quả đáng tin cậy hơn so với hold-out thông thường [99].

Tuy vậy, phương pháp Repeated Hold-out vẫn chưa hoàn hảo. Do các lần lặp chọn mẫu ngẫu nhiên nên có thể xảy ra trùng lặp giữa các tập kiểm tra hoặc một số mẫu không bao giờ được chọn, dẫn đến sự thiên lệch trong ước lượng. Ngoài ra, mỗi lần lặp đều cần xây dựng và đánh giá lại mô hình, khiến chi phí tính toán tăng theo số lần lặp. Do đó, Repeated Hold-out phù hợp khi kích thước dữ liệu đủ lớn và khi cần đánh giá hiệu năng một cách nhanh chóng, nhưng trong các tình huống dữ liệu nhỏ hoặc cần khai thác triệt để dữ liệu thì cross-validation thường mang lại kết quả ổn định hơn [99].

Cross-validation là phương pháp đánh giá mô hình trong học máy bằng cách chia dữ liệu thành nhiều phần (fold), lần lượt dùng một phần để kiểm thử và các phần còn lại để huấn luyện, rồi lấy trung bình kết quả. Độ chính xác ước lượng bằng cross-validation được tính như sau:

$$acc_{cv} = \frac{1}{n} \sum_{(x_i, y_i) \in D_h} \delta(I(D \setminus D_{(i)}, x_i), y_i)$$

Trong đó, n là số lượng mẫu $D_{(i)}$ là fold chứa mẫu x_i , I là mô hình huấn luyện trên dữ liệu còn lại, và $\delta(\hat{y}, y)$ trả về 1 nếu dự đoán đúng và 0 nếu sai. Một số biến thể thường dùng gồm: k-fold cross-validation (chia dữ liệu thành k phần bằng nhau), stratified k-fold (giữ nguyên tỷ lệ lớp trong từng fold), leave-one-out cross-validation – LOOCV (mỗi lần chỉ để lại một mẫu kiểm thử, tận dụng tối đa dữ liệu nhưng rất tốn kém), leave-p-out (tổng quát hóa LOOCV, khó áp dụng với dữ liệu lớn) và repeated cross-validation (lặp lại k-fold nhiều lần để giảm ảnh hưởng ngẫu nhiên). Nhờ sự linh hoạt, cross-validation trở thành công cụ tiêu chuẩn để so sánh và lựa chọn mô hình [98].

Leave-one-out cross-validation (LOOCV) là một trường hợp đặc biệt của cross-validation, trong đó số lượng fold bằng đúng số lượng mẫu trong tập dữ liệu ($k=|D|$). Mỗi fold chỉ chứa một ví dụ và mô hình được huấn luyện trên toàn bộ dữ liệu còn lại. Cách tiếp cận này khai thác triệt để tập dữ liệu ban đầu, không cần bước lấy mẫu ngẫu nhiên, đồng thời không phù hợp để áp dụng phân tầng vì mỗi tập kiểm thử chỉ có một ví dụ. Nhược điểm chính của LOOCV là chi phí tính toán rất cao, đặc biệt khi kích thước dữ liệu lớn. Tuy nhiên, phương pháp này lại phù hợp khi tập dữ liệu ban đầu rất nhỏ, giúp tận dụng tối đa thông tin sẵn có [99].

Ngoại trừ trường hợp leave one out cross-validation vốn tương ứng với complete cross-validation – thì k-fold cross-validation là một phương pháp đánh giá mô hình nhằm khắc phục hạn chế của holdout, tránh hiện tượng trùng lặp hoặc mất cân bằng dữ liệu giữa các tập huấn luyện và kiểm thử [95]. Để cải thiện độ tin cậy, có thể lặp lại quá trình k-fold cross-validation nhiều lần với các cách chia fold khác nhau, từ đó thu được một ước lượng Monte Carlo gần hơn với complete cross-validation, song phải đánh đổi bằng chi phí tính toán lớn hơn [98]. Thông thường mỗi tập con (fold)

được lấy mẫu phân tầng (xấp xỉ phân bố lớp) trước khi áp dụng quá trình đánh giá Cross validation phù hợp khi ta có tập dữ liệu data vừa và nhỏ.

Một biến thể thường dùng là stratified cross-validation, trong đó các fold được phân tầng để đảm bảo tỷ lệ nhãn trong mỗi fold gần giống với phân bố nhãn trong tập dữ liệu gốc. Ngoài ra, một bộ học (inducer) được xem là ổn định nếu nó vẫn tạo ra các bộ phân loại có dự đoán giống nhau khi dữ liệu huấn luyện chịu những nhiễu loạn nhỏ (perturbations) [98].

Bootstrap là một phương pháp ước lượng độ chính xác mô hình khác với cross-validation. Ý tưởng chính là lấy mẫu có hoàn lại (sampling with replacement) từ tập dữ liệu gốc. Với một tập dữ liệu có d mẫu, ta thực hiện chọn ngẫu nhiên d lần, mỗi lần một mẫu có thể được chọn lại nhiều lần, để tạo thành tập huấn luyện (bootstrap sample). Những mẫu không được chọn sẽ tạo thành tập kiểm thử [95].

Một biến thể phổ biến của bootstrap là .632 bootstrap. Ý tưởng dựa trên việc lấy mẫu có hoàn lại từ tập dữ liệu gốc D gồm d phần tử. Xác suất để một mẫu không được chọn sau d lần rút là $\left(1 - \frac{1}{d}\right)^d \approx e^{-1} \approx 0.368$. Do đó, trung bình có khoảng 63.2% mẫu sẽ xuất hiện trong tập huấn luyện (bootstrap sample), trong đó một mẫu có thể lặp lại nhiều lần, và khoảng 36.8% mẫu sẽ tạo thành tập kiểm thử, trong đó mỗi mẫu chỉ xuất hiện tối đa một lần. Chính vì vậy phương pháp này được gọi là “.632 bootstrap”. Phương pháp này đặc biệt phù hợp khi kích thước tập dữ liệu gốc nhỏ, bởi nó tận dụng tốt thông tin sẵn có để vừa huấn luyện vừa kiểm thử mô hình [99].

Về cơ bản, bootstrap có các giả định tương tự như cross-validation, đó là thuật toán huấn luyện cần ổn định trên tập dữ liệu và “thế giới bootstrap” phải phản ánh gần đúng “thế giới thực”. Tuy nhiên, trong một số trường hợp, bootstrap có thể cho kết quả sai lệch. Chẳng hạn, khi sử dụng các mô hình có khả năng ghi nhớ hoàn hảo (perfect memorizer) như cây quyết định không tỉa (unpruned decision tree) hoặc k -NN với $k = 1$, trên một tập dữ liệu hoàn toàn ngẫu nhiên gồm hai lớp. Trong tình huống này, độ chính xác resubstitution đạt 100%, trong khi độ chính xác thực tế chỉ khoảng 50%.

Nếu áp dụng công thức bootstrap, ước lượng thu được vào khoảng 68.4%, chênh lệch khá lớn so với thực tế. Nghiêm trọng hơn, nếu thêm một mô-đun “memorizer” vào bất kỳ mô hình nào và điều chỉnh cách nó dự đoán, thì độ chính xác resubstitution có thể dao động từ 0% đến 100%, khiến kết quả bootstrap bị thiên lệch theo bất kỳ hướng nào mong muốn. Điều này cho thấy bootstrap không phải lúc nào cũng đáng tin cậy, đặc biệt với những mô hình thiên về ghi nhớ dữ liệu huấn luyện thay vì học được quy luật tổng quát [98].

Stratified sampling (lấy mẫu phân tầng) là phương pháp trong đó quần thể nghiên cứu được chia thành những nhóm nhỏ đồng nhất gọi là *tầng* (strata), dựa trên các đặc điểm chung như giới tính, chủng tộc hay vị trí địa lý. Mỗi phần tử chỉ thuộc về một tầng duy nhất. Từ mỗi tầng, nhà nghiên cứu tiếp tục chọn mẫu bằng một phương pháp lấy mẫu xác suất khác, chẳng hạn như lấy mẫu ngẫu nhiên đơn giản hoặc lấy mẫu cụm. Nhờ vậy, các đặc điểm đa dạng của quần thể đều được đại diện

trong mẫu, giúp kết quả nghiên cứu có tính khái quát cao hơn, đáng tin cậy hơn và hạn chế được sai lệch như *undercoverage bias* [100].

Trong lĩnh vực học máy, stratified sampling thường được áp dụng cho các bài toán phân loại, bởi nó đảm bảo rằng ngay cả những lớp có số lượng mẫu ít cũng vẫn được đưa vào huấn luyện và đánh giá, từ đó cải thiện độ tin cậy của mô hình. Tuy nhiên, phương pháp này không thể áp dụng trực tiếp cho các bài toán hồi quy, nơi đầu ra là giá trị liên tục thay vì nhãn lớp [99].

Xét ở góc độ thống kê, stratified sampling giúp tăng độ chính xác của các ước lượng như trung bình hoặc tổng thể dân số. Thay vì chỉ đơn giản tăng kích thước mẫu, phương pháp này hướng đến việc chia quần thể thành các nhóm sao cho biến thiên trong mỗi nhóm là nhỏ nhất, trong khi biến thiên giữa các nhóm là lớn nhất. Sau đó, từ mỗi nhóm sẽ chọn mẫu ngẫu nhiên theo một tỷ lệ thích hợp, để tổng số mẫu đúng bằng kích thước yêu cầu. Quá trình chia nhóm này gọi là *stratification*, và khi việc chọn mẫu trong từng nhóm là ngẫu nhiên thì phương pháp tương ứng được gọi là *stratified random sampling* [101].

Trong stratified simple random sampling, mỗi nhóm được xem như một quần thể độc lập nên kết quả thống kê có thể áp dụng riêng cho từng nhóm. So với simple random sampling, phương pháp này hiệu quả hơn khi sự khác biệt giữa các nhóm lớn hơn biến thiên trong nhóm. Tuy nhiên, độ chính xác đạt được còn phụ thuộc vào cách phân bổ kích thước mẫu. Do đó, khi thiết kế stratified sampling, cần cân nhắc số lượng nhóm, cách phân bổ mẫu và tiêu chí lựa chọn, nhằm giảm phương sai trong phạm vi chi phí cho phép hoặc tối ưu chi phí mà vẫn đảm bảo độ chính xác [101].

TÀI LIỆU THAM KHẢO